

降维习题

浙江大学

赵洲

题目

■ 1. 主成分分析 (PCA) 降维的主要目标是:

- A. 增加数据的维度
- B. 保持数据的主要方差方向
- C. 减少数据的噪声
- D. 提高数据的非线性可分性

解答

■ A. 增加数据的维度

- **错误原因：**PCA的主要目的是**减少**数据的维度，而不是增加。通过选择最具代表性的主成分，PCA在保持数据主要特征的同时降低了数据的复杂性。

解答

■ B. 保持数据的主要方差方向

- **正确：** PCA通过线性变换找到数据中方差最大的方向，这些方向被称为主成分。保留这些主成分能够最大限度地保留数据的变异性和信息量。

解答

■ C. 减少数据的噪声

- **部分正确：** 虽然降维可能间接减少噪声，因为噪声通常分布在较低方差的方向，但PCA的主要目标不是专门去除噪声，而是保留数据的主要变异性。

解答

■ D. 提高数据的非线性可分性

- **错误原因：** PCA是一种线性降维方法，不涉及非线性变换。因此，它并不能直接提高数据的非线性可分性。对于非线性可分性，通常需要使用非线性降维方法如t-SNE或Isomap。

题目

■ 2. 在PCA中，选择前 k 个主成分时，通常是基于：

- A. 主成分的方差贡献率
- B. 主成分的计算复杂度
- C. 主成分的相关性
- D. 主成分的稀疏性

解答

■ A. 主成分的方差贡献率

- **正确**：在PCA中，选择前 k 个主成分通常基于它们的方差贡献率，即选择那些能够解释数据最大方差的主成分。这确保了降维后数据的主要信息被保留。

解答

■ B. 主成分的计算复杂度

- **错误原因：**选择主成分时，计算复杂度不是主要考虑因素。
PCA的目标是保留方差信息，而不是减少计算复杂度。

解答

■ C. 主成分的相关性

- **错误原因：**PCA实际上使得主成分之间**不相关**。选择主成分的标准是它们的方差，而不是相关性。

解答

■ D. 主成分的稀疏性

- **错误原因：** PCA并不关注主成分的稀疏性。稀疏性通常与其他降维方法（如稀疏PCA）相关，而非标准PCA。

题目

■ 3. 在t-SNE算法中，主要用于降低维度的距离度量方法是：

- A. 欧氏距离
- B. 曼哈顿距离
- C. Kullback-Leibler散度
- D. 余弦相似度

解答

■ A. 欧氏距离

- **错误原因：**虽然t-SNE在高维空间中使用欧氏距离来计算相似度，但在降维过程中，其优化目标是最小化高维和低维空间之间的Kullback-Leibler散度。因此，欧氏距离不是t-SNE降维过程中的主要度量方法。

解答

■ B. 曼哈顿距离

- **错误原因：** t-SNE不使用曼哈顿距离作为其主要的距离度量方法。曼哈顿距离在某些场景下可能适用，但不是t-SNE的核心距离度量。

解答

■ C. Kullback-Leibler散度

- **正确：** t-SNE通过最小化高维空间和低维空间之间的Kullback-Leibler散度来优化低维表示。这种散度量用于衡量两个概率分布之间的差异，是t-SNE降维的核心。

解答

■ D. 余弦相似度

- **错误原因：**余弦相似度主要用于衡量向量间的角度相似性，而 t-SNE 并不使用它作为主要的距离度量方法。t-SNE 更关注概率分布之间的差异。

题目

■ 4. 以下哪种降维方法是线性的？

- A. t-SNE
- B. PCA
- C. Isomap
- D. LLE

解答

■ A. t-SNE

- **错误原因：** t-SNE是一种**非线性**降维方法，主要用于高维数据的可视化，通过保留局部结构来展示数据的低维表示。

解答

■ B. PCA

- **正确**: PCA是一种**线性**降维方法, 通过线性组合原始特征来找到新的主成分方向, 最大化数据在这些方向上的方差。

解答

■ C. Isomap

- **错误原因：** Isomap是一种**非线性**降维方法，通过保持数据的测地距离（沿流形的距离）来实现降维。

解答

■ D. LLE

- **错误原因：**局部线性嵌入（LLE）也是一种**非线性**降维方法，通过保持局部邻域的线性关系来实现降维。

题目

- 判断1.
- LDA（线性判别分析）不仅可以用于降维，还可以用于分类。

解答

- 正确

- LDA既是一种降维技术，通过寻找能够最大化类间方差和最小化类内方差的投影方向，也是一种分类方法，特别是在监督学习中，用于构建判别函数来区分不同类别。

题目

- 判断2.
- PCA在降维过程中会考虑数据的类别信息。

解答

■ 错误

- **错误原因：**PCA是一种**无监督**的降维方法，它只关注数据的整体方差，**不考虑任何类别信息或标签**。PCA通过线性变换保留数据的主要变异性，而不区分类别，因此无法利用类别信息来指导降维过程。

题目

- 判断3.
- 降维后，数据的解释性通常会提高。

解答

■ 错误

- 降维的主要目的是减少数据的复杂性和维度，而不一定提高数据的解释性。实际上，降维可能会丢失一些原始数据的信息，使得某些特征难以解释。然而，降维可以通过简化数据结构，使得某些模式更易于识别，但这不等同于整体解释性的提高。

题目

- 判断4.
- t-SNE适合用于高维数据的可视化，尤其是二维或三维。

解答

- 正确

- t-SNE是一种**非线性**降维技术，特别适用于将高维数据降到**二维或三维**，以便于可视化。它通过保留数据点之间的局部结构，使得在低维空间中能够直观地展示数据的聚类 and 分布。

题目

■ 1. 主成分分析 (PCA) 的计算

- a) 计算数据的均值向量。
- b) 对数据进行中心化。
- c) 计算协方差矩阵。
- d) 求出协方差矩阵的特征值和特征向量。
- e) 选择第一个主成分，并将数据降维到一维。

样本	x_1	x_2
1	2	0
2	0	2
3	2	2
4	0	0

解答

a) 计算均值向量

$$\mu = \left(\frac{2 + 0 + 2 + 0}{4}, \frac{0 + 2 + 2 + 0}{4} \right) = (1, 1)$$

详细解释：

- 对每个特征 (x_1 和 x_2) 分别求平均值。
- 计算过程：
 - x_1 的平均值: $(2 + 0 + 2 + 0)/4 = 1$
 - x_2 的平均值: $(0 + 2 + 2 + 0)/4 = 1$
- 因此, 均值向量为 $\mu = (1, 1)$ 。

解答

b) 对数据进行中心化

$$\text{样本1: } (2 - 1, 0 - 1) = (1, -1)$$

$$\text{样本2: } (0 - 1, 2 - 1) = (-1, 1)$$

$$\text{样本3: } (2 - 1, 2 - 1) = (1, 1)$$

$$\text{样本4: } (0 - 1, 0 - 1) = (-1, -1)$$

详细解释:

- 中心化是指从每个数据点中减去均值向量，以使数据的均值为零。
- 计算过程：
 - 样本1: $(2 - 1, 0 - 1) = (1, -1)$
 - 样本2: $(0 - 1, 2 - 1) = (-1, 1)$
 - 样本3: $(2 - 1, 2 - 1) = (1, 1)$
 - 样本4: $(0 - 1, 0 - 1) = (-1, -1)$
- 中心化后的数据集为: $[(1, -1), (-1, 1), (1, 1), (-1, -1)]$

解答

c) 计算协方差矩阵

$$\text{Cov} = \frac{1}{4} \begin{bmatrix} 1 & -1 & 1 & -1 \\ -1 & 1 & 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ 1 & 1 \\ -1 & -1 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

详细解释：

- 协方差矩阵的计算公式为：

$$\text{Cov}(X) = \frac{1}{n} X^T X$$

解答

其中, X 是中心化后的数据矩阵, n 是样本数量。

- 中心化后的数据矩阵:

$$X = \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ 1 & 1 \\ -1 & -1 \end{bmatrix}$$

- 计算 $X^T X$:

$$X^T X = \begin{bmatrix} 1 & -1 & 1 & -1 \\ -1 & 1 & 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ 1 & 1 \\ -1 & -1 \end{bmatrix} = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

- 因此, 协方差矩阵为:

$$\text{Cov} = \frac{1}{4} \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

解答

d) 求协方差矩阵的特征值和特征向量

协方差矩阵为单位矩阵，其特征值和特征向量如下：

$$\lambda_1 = 1, \quad \mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$\lambda_2 = 1, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

详细解释：

- 单位矩阵的特征值均为1，对应的特征向量可以是标准基向量 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 和 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 。
- 由于协方差矩阵是对角矩阵，各对角线元素即为特征值，且特征向量是标准基向量。

解答

e) 选择第一个主成分，并将数据降维到一维

选择 $\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 作为主成分。

投影计算：

$$\text{样本1: } 1 \times 1 + (-1) \times 0 = 1$$

$$\text{样本2: } -1 \times 1 + 1 \times 0 = -1$$

$$\text{样本3: } 1 \times 1 + 1 \times 0 = 1$$

$$\text{样本4: } -1 \times 1 + (-1) \times 0 = -1$$

降维后的一维数据：1, -1, 1, -1。

解答

详细解释：

- 主成分 \mathbf{v}_1 为 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ ，表示沿 x_1 轴的方向。
- 投影过程为将每个中心化后的数据点与主成分进行点积计算，得到一维表示。
 - 样本1: $1 \times 1 + (-1) \times 0 = 1$
 - 样本2: $-1 \times 1 + 1 \times 0 = -1$
 - 样本3: $1 \times 1 + 1 \times 0 = 1$
 - 样本4: $-1 \times 1 + (-1) \times 0 = -1$
- 降维后的数据为 $[1, -1, 1, -1]$ 。

总结：通过PCA，原始二维数据被投影到一维主成分上，保留了数据在 x_1 方向上的变异性。

题目

- 2. LDA的计算
- 假设有两类数据，各有两个样本
- 使用线性判别分析（LDA）进行降维，求投影方向。

类1: $(2,0), (4,0)$

类2: $(0,2), (0,4)$

解答

1. 计算每类的均值:

$$\mu_1 = \left(\frac{2+4}{2}, \frac{0+0}{2} \right) = (3, 0)$$

$$\mu_2 = \left(\frac{0+0}{2}, \frac{2+4}{2} \right) = (0, 3)$$

详细解释:

- 类1的均值:
 - x_1 均值: $(2+4)/2 = 3$
 - x_2 均值: $(0+0)/2 = 0$
- 类2的均值:
 - x_1 均值: $(0+0)/2 = 0$
 - x_2 均值: $(2+4)/2 = 3$

解答

2. 计算类内散布矩阵 S_W :

- 对于类1:

$$S_{W1} = \sum_{i=1}^2 (\mathbf{x}_i - \mu_1)(\mathbf{x}_i - \mu_1)^T = \begin{bmatrix} (2-3)^2 & 0 \\ 0 & (0-0)^2 \end{bmatrix} + \begin{bmatrix} (4-3)^2 & 0 \\ 0 & (0-0)^2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}$$

- 对于类2:

$$S_{W2} = \sum_{i=1}^2 (\mathbf{x}_i - \mu_2)(\mathbf{x}_i - \mu_2)^T = \begin{bmatrix} (0-0)^2 & 0 \\ 0 & (2-3)^2 \end{bmatrix} + \begin{bmatrix} (0-0)^2 & 0 \\ 0 & (4-3)^2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}$$

- 总的类内散布矩阵:

$$S_W = S_{W1} + S_{W2} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

解答

详细解释：

- 类内散布矩阵衡量每个类内数据的分散程度。
- 对于每个类，计算每个样本与该类均值的差，并计算其外积，然后累加。
- 类1的样本偏离均值的差分别为 $(2 - 3, 0 - 0) = (-1, 0)$ 和 $(4 - 3, 0 - 0) = (1, 0)$ ，其散布矩阵为：

$$S_{W1} = (-1)^2 + (1)^2 = 2 \quad \text{在} x_1 \text{ 方向上有散布}$$

- 类2的样本偏离均值的差分别为 $(0 - 0, 2 - 3) = (0, -1)$ 和 $(0 - 0, 4 - 3) = (0, 1)$ ，其散布矩阵为：

$$S_{W2} = (-1)^2 + (1)^2 = 2 \quad \text{在} x_2 \text{ 方向上有散布}$$

- 总的类内散布矩阵为：

$$S_W = S_{W1} + S_{W2} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

解答

3. 计算类间散布矩阵 S_B :

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T = \begin{bmatrix} 3 & -0 \\ 0 & -3 \end{bmatrix} \begin{bmatrix} 3 & -3 \end{bmatrix} = \begin{bmatrix} 9 & -9 \\ -9 & 9 \end{bmatrix}$$

详细解释:

- 类间散布矩阵衡量不同类之间均值的分离程度。
- 计算方法是类间均值差的外积。
- $\mu_1 - \mu_2 = (3 - 0, 0 - 3) = (3, -3)$
- 类间散布矩阵:

$$S_B = \begin{bmatrix} 3 \\ -3 \end{bmatrix} \begin{bmatrix} 3 & -3 \end{bmatrix} = \begin{bmatrix} 9 & -9 \\ -9 & 9 \end{bmatrix}$$

解答

4. 计算 $S_W^{-1}S_B$:

$$S_W^{-1} = \frac{1}{2} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$S_W^{-1}S_B = \frac{1}{2} \begin{bmatrix} 9 & -9 \\ -9 & 9 \end{bmatrix} = \begin{bmatrix} 4.5 & -4.5 \\ -4.5 & 4.5 \end{bmatrix}$$

详细解释:

- 计算 S_W^{-1} , 由于 S_W 是对角矩阵, 逆矩阵也容易计算:

$$S_W^{-1} = \frac{1}{2} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

- 计算 $S_W^{-1}S_B$:

$$S_W^{-1}S_B = \frac{1}{2} \times \begin{bmatrix} 9 & -9 \\ -9 & 9 \end{bmatrix} = \begin{bmatrix} 4.5 & -4.5 \\ -4.5 & 4.5 \end{bmatrix}$$

解答

5. 求特征值和特征向量：

矩阵 $\begin{bmatrix} 4.5 & -4.5 \\ -4.5 & 4.5 \end{bmatrix}$ 的特征值和特征向量如下：

- 特征值：9 和 0
- 对应的特征向量：
 - 对于特征值9: $\mathbf{v}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$
 - 对于特征值0: $\mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

解答

详细解释:

- 求解特征值:

$$\det \left(\begin{bmatrix} 4.5 - \lambda & -4.5 \\ -4.5 & 4.5 - \lambda \end{bmatrix} \right) = (4.5 - \lambda)^2 - (-4.5)^2 = 0$$
$$(4.5 - \lambda)^2 = 20.25 \implies 4.5 - \lambda = \pm 4.5 \implies \lambda = 9 \text{ 或 } 0$$

- 对于 $\lambda = 9$:

$$\begin{bmatrix} 4.5 - 9 & -4.5 \\ -4.5 & 4.5 - 9 \end{bmatrix} = \begin{bmatrix} -4.5 & -4.5 \\ -4.5 & -4.5 \end{bmatrix}$$

解方程:

$$-4.5x - 4.5y = 0 \implies x = -y$$

选择特征向量为 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 。

- 对于 $\lambda = 0$:

$$\begin{bmatrix} 4.5 & -4.5 \\ -4.5 & 4.5 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 0$$

解方程:

$$4.5x - 4.5y = 0 \implies x = y$$

选择特征向量为 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。

解答

6. 选择最大特征值对应的特征向量作为投影方向：

$$\mathbf{w} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

详细解释：

- 在LDA中，选择对应于最大特征值的特征向量作为投影方向，以最大化类间散布与类内散布的比率。
- 最大特征值为9，对应的特征向量为 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ ，因此投影方向为 $(1, -1)$ 。

总结：通过LDA，找到最能区分两类数据的投影方向为 $(1, -1)$ ，即沿此方向将数据降维。

题目

- 3. 奇异值分解 (SVD) 与PCA
- 解释奇异值分解 (SVD) 如何用于实现PCA, 并说明其中的关键步骤。

解答

奇异值分解（SVD）可以用于计算PCA的主成分。关键步骤如下：

1. **数据中心化**：将数据矩阵 X 的每个特征减去其均值，使数据中心化。

详细解释：

- 数据中心化是PCA的第一步，确保每个特征的均值为零，以避免均值对主成分的影响。
- 中心化后的数据矩阵 X 具有零均值。

解答

2. **SVD分解**：对中心化后的数据矩阵 X 进行SVD分解：

$$X = U\Sigma V^T$$

其中， U 和 V 是正交矩阵， Σ 是对角矩阵，包含奇异值。

详细解释：

- SVD将数据矩阵分解为三个矩阵的乘积。
- U ：表示数据在左奇异向量方向上的投影。
- Σ ：包含奇异值，反映数据在各主成分方向上的方差。
- V^T ：表示主成分方向，即特征向量。

解答

3. **主成分选择**: 矩阵 V 的列向量即为PCA的主成分。选择前 k 个对应最大奇异值的列向量作为前 k 个主成分。

详细解释:

- 奇异值的大小与对应主成分的方差成正比。
- 选择前 k 个最大奇异值对应的主成分，确保最大程度地保留数据的变异性。

解答

4. 数据投影：将数据投影到选择的主成分上，即计算：

$$X_{\text{降维}} = XV_k$$

其中， V_k 是前k个主成分组成的矩阵。

详细解释：

- 通过将中心化后的数据矩阵与主成分矩阵相乘，实现数据在新低维空间的表示。
- 结果 $X_{\text{降维}}$ 是降维后的数据，保留了主要的方差信息。

解答

- **总结：** 通过SVD，PCA的计算过程变得更加高效，尤其适用于大规模数据集。SVD分解提供了主成分和对应的奇异值，帮助我们选择保留最重要的特征进行降维。

End