

# 机器学习导论

## 第三讲 线性模型



# 机器学习模型引线

---

- 基础机器学习模型：线性模型
    - 高级模型：支持向量机、神经网络等
    - 高级模型：统计学习方法和理论
  - 基础机器学习模型：决策树
    - 高级模型：Adaboost，随机森林，GBDT等
  - 基础机器学习模型：贝叶斯模型
    - 高级模型：图模型等
-

# 提纲

---

- 线性模型引言
  - 回归任务（模型：最小二乘法）
  - 二分类任务（模型：对数几率回归、线性判别分析）
  - 多分类任务（模型：一对一、一对其余、多对多）
  - 类别不平衡任务
-

# 基本形式

---

- 线性模型一般形式

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

- 向量形式

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$


其中

$$\mathbf{w} = (w_1; w_2; \dots; w_d) \quad \mathbf{x} = (x_1; x_2; \dots; x_d)$$


---

# 一个典型的线性模型

如何区分猫、狗 等



# 另一个典型的线分



# Perceptron 感知机

对于线性分类器，误分类则：

$$y_i(w \cdot x_i + b) > 0$$

所以可以顺势定义损失函数

$$L(w, b) = - \sum_{x_i \in M} y_i(w \cdot x_i + b)$$





梯度：

$$\nabla_w L(w, b) = - \sum_{x_i \in M} y_i x_i$$

$$\nabla_b L(w, b) = - \sum_{x_i \in M} y_i$$


$$w := w + \eta y_i x_i$$

$$b := b + \eta y_i$$



# revisit : 梯度下降法

---





# revisit : 梯度下降法

---

- 一阶方法
- 无约束优化

考虑无约束优化问题  $\min_{\mathbf{x}} f(\mathbf{x})$ , 其中  $f(\mathbf{x})$  为连续可微函数. 若能构造一个序列  $\mathbf{x}^0, \mathbf{x}^1, \mathbf{x}^2, \dots$  满足

$$f(\mathbf{x}^{t+1}) < f(\mathbf{x}^t), \quad t = 0, 1, 2, \dots$$

$$f(\mathbf{x} + \Delta \mathbf{x}) = f(\mathbf{x}) + \underbrace{\Delta \mathbf{x}^\top \nabla f(\mathbf{x})}$$

$$< 0$$




$$\Delta \mathbf{x} = -\gamma \nabla f(\mathbf{x})$$

---

# 线性模型优点

---

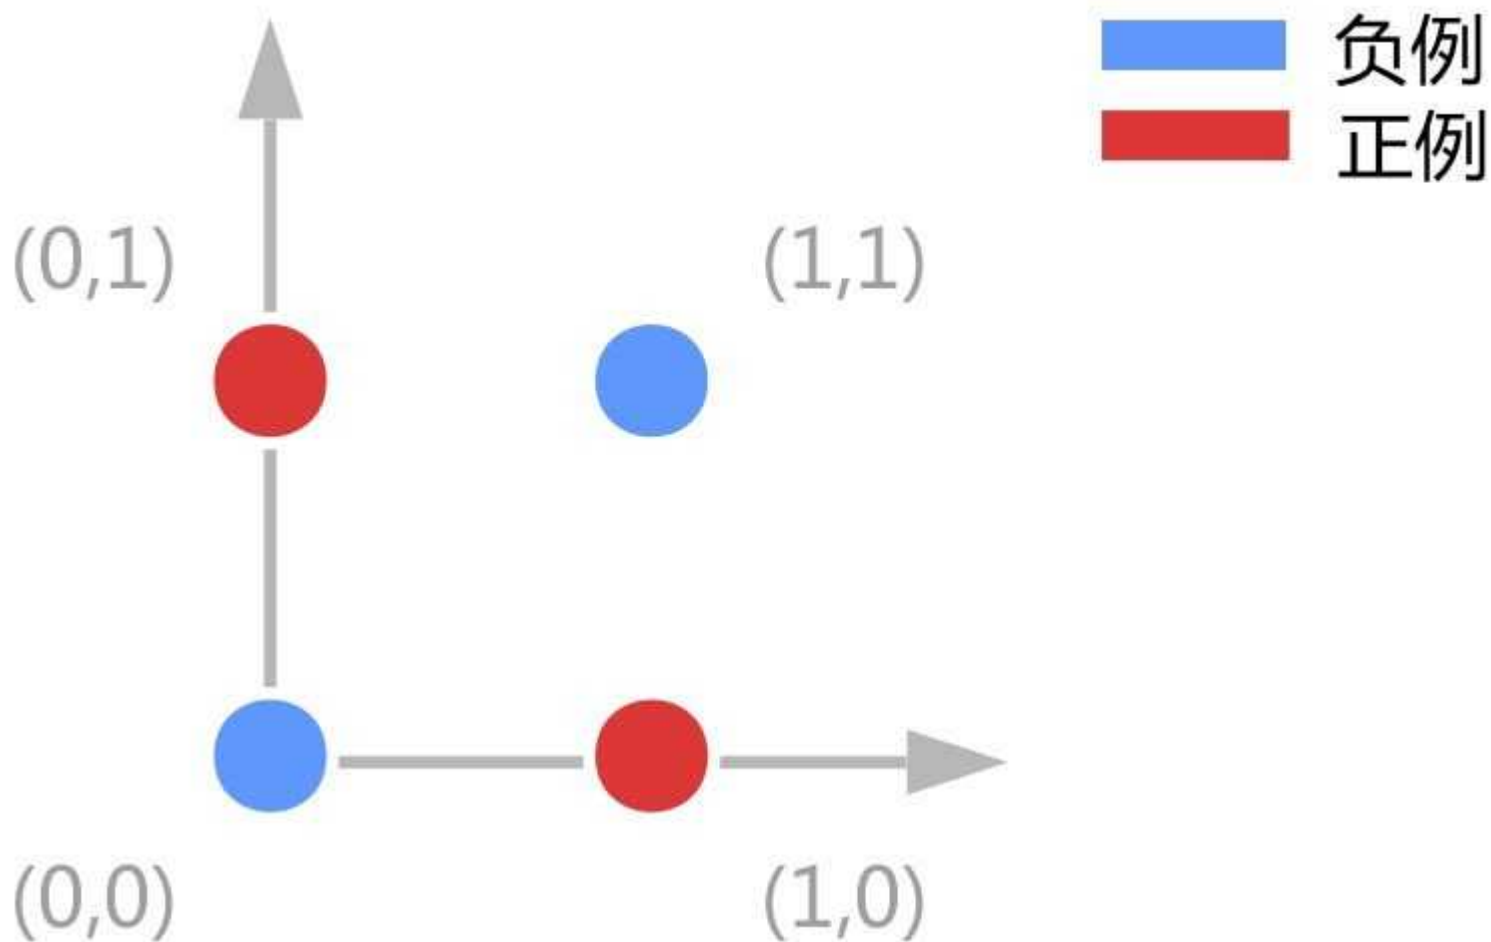
- 形式简单、易于建模
- 可解释性
- 非线性模型的基础
  - 引入层级结构或高维映射



- 一个例子  $f_{\text{好瓜}}(\mathbf{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$ 
  - 综合考虑色泽、根蒂和敲声来判断西瓜好不好
  - 其中根蒂的系数最大，表明根蒂对判别好坏最重要；而敲声的系数比色泽大，说明敲声比色泽更重要

# 线性模型的缺陷

---



# 提纲

---

- 线性模型引言
  - 回归任务（模型：最小二乘法）
  - 二分类任务（模型：对数几率回归、线性判别分析）
  - 多分类任务（模型：一对一、一对其余、多对多）
  - 类别不平衡任务
-

# 线性回归

---

- 给定数据集  $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$

其中

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$$



- 线性回归（linear regression）目的
    - 学得一个线性模型以尽可能准确地预测实值输出标记
  - 离散属性处理
    - 有“序”关系
      - 连续化为连续值
    - 无“序”关系
      - 有k个属性值，则转换为k维向量
-

# 线性回归

---

- 单一属性的线性回归目标

$$f(x) = wx_i + b \quad \text{使得} \quad f(x_i) \simeq y_i$$

- 参数/模型估计：最小二乘法（least square method）

$$\begin{aligned}(w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2\end{aligned}$$

---

# 线性回归 – 最小二乘法

---

- 最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$$

- 分别对  $w$  和  $b$  求导, 可得

$$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right)$$

---

# 线性回归 - 最小二乘法

---

- 得到闭式（closed-form）解

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

其中

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

---



# 多元线性回归

---

- 给定数据集

$$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$$

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$$

- 多元线性回归目标

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b \text{ 使得 } f(\mathbf{x}_i) \simeq y_i$$


---

# 多元线性回归 – 齐次表达

- 把  $w$  和  $b$  吸收入向量形式  $\hat{w} = (w; b)$ ，数据集表示为

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

$$\mathbf{y} = (y_1; y_2; \dots; y_m)$$



# 多元线性回归 - 最小二乘法

---

□ 最小二乘法 (least square method)

$$\hat{\boldsymbol{w}}^* = \arg \min_{\hat{\boldsymbol{w}}} (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})^T (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}}) .$$

令  $E_{\hat{\boldsymbol{w}}} = (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})^T (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})$  , 对  $\hat{\boldsymbol{w}}$  求导得到

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\boldsymbol{X}^T (\boldsymbol{X}\hat{\boldsymbol{w}} - \boldsymbol{y})$$

令上式为零可得  $\hat{\boldsymbol{w}}$  最优解的闭式解

---

# 多元线性回归 – 满秩讨论

---

□  $\mathbf{X}^T \mathbf{X}$  是满秩矩阵或正定矩阵，则

$$\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

其中  $(\mathbf{X}^T \mathbf{X})^{-1}$  是  $\mathbf{X}^T \mathbf{X}$  的逆矩阵，线性回归模型为


$$f(\hat{\mathbf{x}}_i) = \hat{\mathbf{x}}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

□  $\mathbf{X}^T \mathbf{X}$  不是满秩矩阵

- 引入正则化（参见6.4节，11.4节）

# 对数线性回归

- 输出标记的对数为线性模型逼近的目标



$$\ln y = w^T x + b$$



$$y = w^T x + b$$

# 线性回归 - 广义线性模型

---

- 一般形式

$$y = g^{-1}(w^T x + b)$$

- $g(\cdot)$  为联系函数 (link function)

- 单调可微函数

- 对数线性回归是  $g(\cdot) = \ln(\cdot)$  广义线性模型的特例

# 提纲

---

- 线性模型引言
  - 回归任务（模型：最小二乘法）
  - 二分类任务（模型：对数几率回归、线性判别分析）
  - 多分类任务（模型：一对一、一对其余、多对多）
  - 类别不平衡任务
-

# 二分类任务

---

- 预测值与输出标记

$$z = \mathbf{w}^T \mathbf{x} + b$$

$$y \in \{0, 1\}$$

- 寻找函数将分类标记与线性回归模型输出联系起来

- 最理想的函数——单位阶跃函数

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$


- 预测值大于零就判为正例，小于零就判为反例，预测值为临界值零则可任意判别
-



# 二分类任务

- 单位阶跃函数缺点
  - 不连续
- 替代函数——对数几率函数（logistic function）
  - 单调可微、任意阶可导 *单位阶跃函数与对数几率函数的比较*

$$y = \frac{1}{1 + e^{-z}}$$



# 对数几率回归

---

- 运用对数几率函数

$$y = \frac{1}{1 + e^{-z}} \quad \text{变为} \quad y = \frac{1}{1 + e^{-(w^T x + b)}}$$

- 对数几率 (log odds)
  - 样本作为正例的相对可能性的对数

$$\ln \frac{y}{1-y}$$

- 对数几率回归的优势
    1. 无需事先假设数据分布
    2. 可得到“类别”的近似概率预测
    3. 可直接应用现有数值优化算法求取最优解
-

# 对数几率回归 – 极大似然法

---

- 对数几率

$$\ln \frac{p(y=1 \mid \mathbf{x})}{p(y=0 \mid \mathbf{x})} = \mathbf{w}^T \mathbf{x} + b$$

显然有

$$p(y=1 \mid \mathbf{x}) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

$$p(y=0 \mid \mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

---

# 对数几率回归 - 极大似然法

---

- 极大似然法 (maximum likelihood)

- 给定数据集

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^m$$

- 最大化样本属于其真实标记的概率

- 最大化对数似然函数

$$\ell(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i | \mathbf{x}_i; \mathbf{w}, b)$$

# 对数几率回归 – 极大似然法

---

- 转化为最小化负对数似然函数求解

– 令  $\beta = [w; b]$ ,  $\hat{x} = (x; 1)$ , 则  $w^T x + b$  可简写为

– 再令  $p_1(\hat{x}_i; \beta) = p(y = 1 \mid \hat{x}_i; \beta)$

$$p_0(\hat{x}_i; \beta) = p(y = 0 \mid \hat{x}_i; \beta) = 1 - p_1(\hat{x}_i; \beta)$$

$$p(y_i \mid x_i; w_i, b) = y_i p_1(\hat{x}_i; \beta) + (1 - y_i) p_0(\hat{x}_i; \beta)$$

则似然项可重写为

$$\ell(\beta) = \sum_{i=1}^m \left( -y_i \beta^T \hat{x}_i + \ln \left( 1 + e^{\beta^T \hat{x}_i} \right) \right)$$

---

# 对数几率回归

---

□ 求解得

$$\beta^* = \arg \min_{\beta} \ell(\beta)$$

□ 牛顿法第  $t+1$  轮迭代解的更新公式

$$\beta^{t+1} = \beta^t - \left( \frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^T} \right)^{-1} \frac{\partial \ell(\beta)}{\partial \beta}$$

其中关于  $\beta$  的一阶、二阶导数分别为

$$\frac{\partial \ell(\beta)}{\partial \beta} = - \sum_{i=1}^m \hat{\mathbf{x}}_i (y_i - p_1(\hat{\mathbf{x}}_i; \beta))$$

$$\frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^T} = \sum_{i=1}^m \hat{\mathbf{x}}_i \hat{\mathbf{x}}_i^T p_1(\hat{\mathbf{x}}_i; \beta) (1 - p_1(\hat{\mathbf{x}}_i; \beta))$$

高阶可导连续凸函数，梯度下降法/牛顿法 [Boyd and Vandenberghe, 2004]

---

# 对数几率回归 ( logistic regression, LR )


---

- 主要建模思想：
    - 引入sigmoid函数，建立离散标记与线性模型的关联
    - sigmoid函数光滑，高阶可导，高度接近离散标记
    - 得到类别的概率似然估计
    - 构建极大似然目标函数
    - 优化求解：梯度下降、牛顿法等
  - 主要优势
    - 可以具有类别的概率估计输出，辅助决策
    - 可以自然扩展到多类任务（思考）
    - LR具有唯一最优解（思考：凸函数）
-

# 二分类任务- 线性判别分析

- 线性判别分析 (Linear Discriminant Analysis)

[Fisher, 1936]



LDA也可被视为一种  
监督降维技术



# 二分类任务- 线性判别分析

---

- LDA的思想

- 欲使同类样例的投影点尽可能接近，可以让同类样例投影点的协方差尽可能小
- 欲使异类样例的投影点尽可能远离，可以让类中心之间的距离尽可能大

- 一些变量

- 第 $i$ 类示例的集合  $X_i$
  - 第 $i$ 类示例的均值向量  $\mu_i$
  - 第 $i$ 类示例的协方差矩阵  $\Sigma_i$
  - 两类样本的中心在直线上的投影:  $w^T \mu_1$        $w^T \mu_2$
  - 两类样本的协方差:  $w^T \Sigma_1 w$        $w^T \Sigma_2 w$
-

# 二分类任务 - 线性判别分析

---

- 最大化目标

$$\begin{aligned} J &= \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} \\ &= \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w} \end{aligned}$$

- 类内散度矩阵

$$\begin{aligned} S_w &= \Sigma_0 + \Sigma_1 \\ &= \sum_{x \in X_0} (x - \mu_0) (x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1) (x - \mu_1)^T \end{aligned}$$

- 类间散度矩阵  $S_b = (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T$
-

# 二分类任务– 线性判别分析

---

- 广义瑞利商 (generalized Rayleigh quotient)

$$J = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

- 令  $\mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1$  最大化广义瑞利商等价形式为

$$\begin{aligned} \min_{\mathbf{w}} \quad & -\mathbf{w}^T \mathbf{S}_b \mathbf{w} \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{S}_w \mathbf{w} = 1 \end{aligned}$$

- 运用拉格朗日乘子法  $\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$
-

# revisit：拉格朗日乘子法

---

- 对于约束曲面上的任意点  $\boldsymbol{x}$ , 该点的梯度  $\nabla g(\boldsymbol{x})$  正交于约束曲面;
- 在最优点  $\boldsymbol{x}^*$ , 目标函数在该点的梯度  $\nabla f(\boldsymbol{x}^*)$  正交于约束曲面.

由此可知, 在最优点  $\boldsymbol{x}^*$ , 如附图 1 所示, 梯度  $\nabla g(\boldsymbol{x})$  和  $\nabla f(\boldsymbol{x})$  的方向必相同或相反, 即存在  $\lambda \neq 0$  使得

$$\nabla f(\boldsymbol{x}^*) + \lambda \nabla g(\boldsymbol{x}^*) = 0, \quad (\text{B.1})$$


$\lambda$  称为拉格朗日乘子. 定义拉格朗日函数

$$L(\boldsymbol{x}, \lambda) = f(\boldsymbol{x}) + \lambda g(\boldsymbol{x}), \quad (\text{B.2})$$


---

# revisit : 拉格朗日乘子法

---



(a) 等式约束



(b) 不等式约束

# 二分类任务- 线性判别分析

---

$$\mathbf{w} = \lambda^{-1} \mathbf{S}_w^{-1} \mathbf{S}_b \mathbf{w} = \lambda^{-1} \mathbf{S}_w^{-1} (\mu_0 - \mu_1) (\mu_0 - \mu_1)^\top \mathbf{w}$$

- 结果

$$\mathbf{w} = \mathbf{S}_w^{-1} (\mu_0 - \mu_1)$$

- 求解

- 奇异值分解

$$\mathbf{S}_w = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$$

- LDA的贝叶斯决策论解释

- 两类数据同先验、满足高斯分布且协方差相等时，LDA达到最优分类

# LDA推广- 多分类任务

---

- 全局散度矩阵

$$\begin{aligned}\mathbf{S}_t &= \mathbf{S}_b + \mathbf{S}_w \\ &= \sum_{i=1}^m (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T\end{aligned}$$

- 类内散度矩阵

$$\mathbf{S}_w = \sum_{i=1}^N \mathbf{S}_{w_i}$$

其中  $\mathbf{S}_{w_i} = \sum_{\mathbf{x} \in X_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^T$

$$\begin{aligned}\mathbf{S}_b &= \mathbf{S}_t - \mathbf{S}_w \\ &= \sum_{i=1}^N m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T\end{aligned}$$

---

# LDA推广—多分类任务

---

- 优化目标

$$\max_{\mathbf{W}} \frac{\text{tr}(\mathbf{W}^T \mathbf{S}_b \mathbf{W})}{\text{tr}(\mathbf{W}^T \mathbf{S}_w \mathbf{W})}$$

其中  $\mathbf{W} \in \mathbb{R}^{d \times (N-1)}$



$$\mathbf{S}_b \mathbf{W} = \lambda \mathbf{S}_w \mathbf{W}$$

$\mathbf{W}$  的闭式解则是  $\mathbf{S}_w^{-1} \mathbf{S}_b$  的  $N-1$  个最大广义特征值所对应的特征向量组成的矩阵

- 多分类LDA将样本投影到 $N-1$ 维空间， $N-1$ 通常远小于数据原有的属性数，因此LDA也被视为一种监督降维技术
-



# LDA

---

- 主要建模思想：

- 寻找线性超平面，使得同类样例的投影点尽可能接近，异类样例的投影点尽可能远离
- 得到广义瑞利商形式，设计巧妙
- 得到最优解，是个闭式解

- 历史地位

- LDA能够用于分类任务，但是因为其目标函数不直接对应经验风险，性能不如直接优化经验风险的方法
  - 因LDA投影点有效地得到类别区分方向，保留大量类别之前的判别信息，LDA成为数据降维最主流的方法之一
-

# 提纲

---

- 线性模型引言
  - 回归任务（模型：最小二乘法）
  - 二分类任务（模型：对数几率回归、线性判别分析）
  - 多分类任务（模型：一对一、一对其余、多对多）
  - 类别不平衡任务
-

# 多分类学习

---

- 多分类任务

## Binary Classification



- Spam
- Not spam

## Multiclass Classification




- Dog
- Cat
- Horse
- Fish
- Bird
- ...

# 多分类学习


---

- 多分类任务

Binary classification:



Multi-class classification:



# 多分类学习

---

- 多分类学习方法

- 常用技巧：利用二分类学习器解决多分类问题

- 对问题进行拆分，为拆出的每个二分类任务训练一个分类器
    - 对于每个分类器的预测结果进行集成以获得最终的多分类结果

- 拆分策略

- 一对一 (One vs. One, OvO)
    - 一对其余 (One vs. Rest, OvR)
    - 多对多 (Many vs. Many, MvM)
-

# 多分类学习- 一对一

---

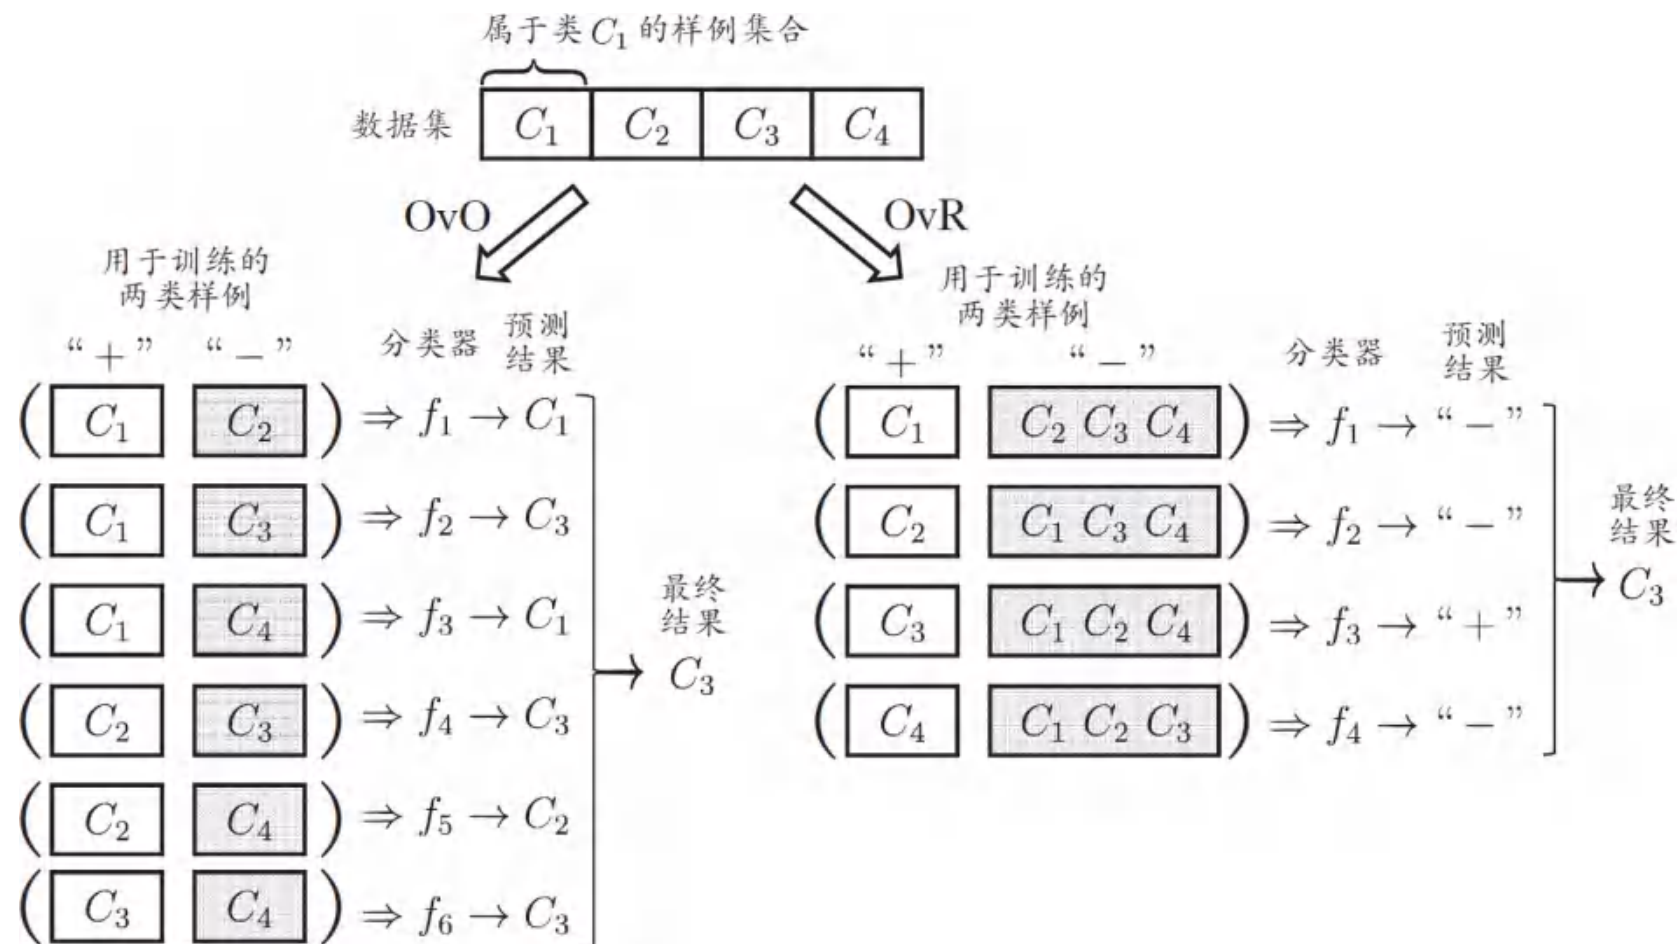
- 拆分阶段
    - N个类别两两配对
      - $N(N-1)/2$  个二类任务
    - 各个二类任务学习分类器
      - $N(N-1)/2$  个二类分类器
  - 测试阶段
    - 新样本提交给所有分类器预测
      - $N(N-1)/2$  个分类结果
    - 投票产生最终分类结果
      - 被预测最多的类别为最终类别
-

# 多分类学习—一对其余

---

- 任务拆分
    - 某一类作为正例，其他反例
      - $N$  个二类任务
    - 各个二类任务学习分类器
      - $N$  个二类分类器
  - 测试阶段
    - 新样本提交给所有分类器预测
      - $N$  个分类结果
    - 比较各分类器预测置信度
      - 置信度最大类别作为最终类别
-

# 多分类学习 - 两种策略比较





# 多分类学习 - 两种策略比较

---

## 一对一

- 训练 $N(N-1)/2$ 个分类器，  
存储开销和测试时间大
- 训练只用两个类的样例，  
训练时间短

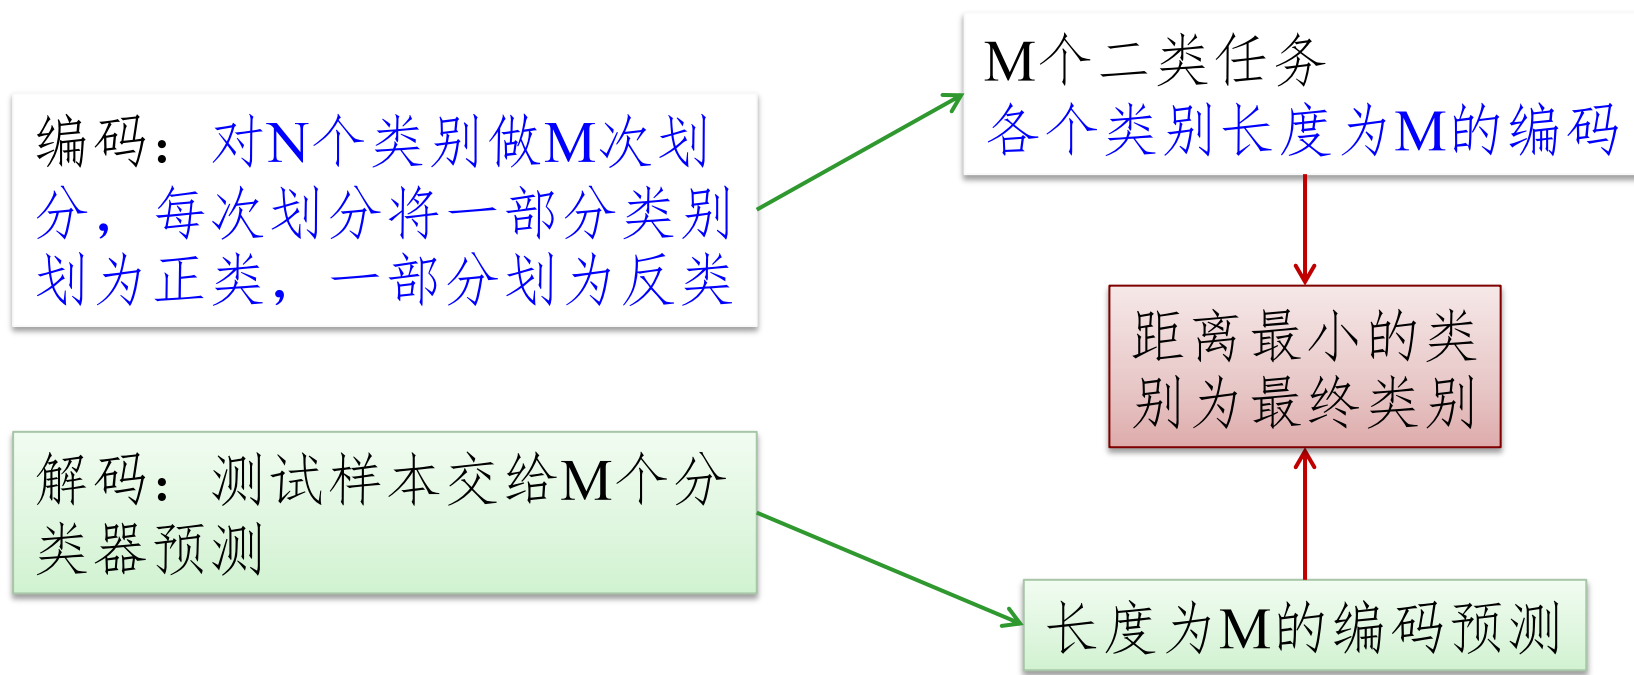
## 一对其余

- 训练 $N$ 个分类器，存储开销和测试时间小
- 训练用到全部训练样例，  
训练时间长

预测性能取决于具体数据分布


# 多分类学习– 多对多

- 多对多 (Many vs Many, MvM)
  - 若干类作为正类, 若干类作为反类
- ▣ 纠错输出码 (Error Correcting Output Code, ECOC)



# 多分类学习- 多对多

- 纠错输出码 (Error Correcting Output Code, ECOC)



- ECOC编码对分类器错误有容忍和修正能力，编码越长、纠错能力越强
- 对同等长度的编码，理论上来说，任意两个类别之间的编码距离越远，则纠错能力越强

# 提纲


---

- 线性模型引言
  - 回归任务（模型：最小二乘法）
  - 二分类任务（模型：对数几率回归、线性判别分析）
  - 多分类任务（模型：一对一、一对其余、多对多）
  - 类别不平衡任务
-

# 类别不平衡问题

---

- 类别不平衡




# 类别不平衡问题

---

- 类别不平衡（class imbalance）
  - 不同类别训练样例数相差很大情况（正类为小类）

类别平衡正例预测



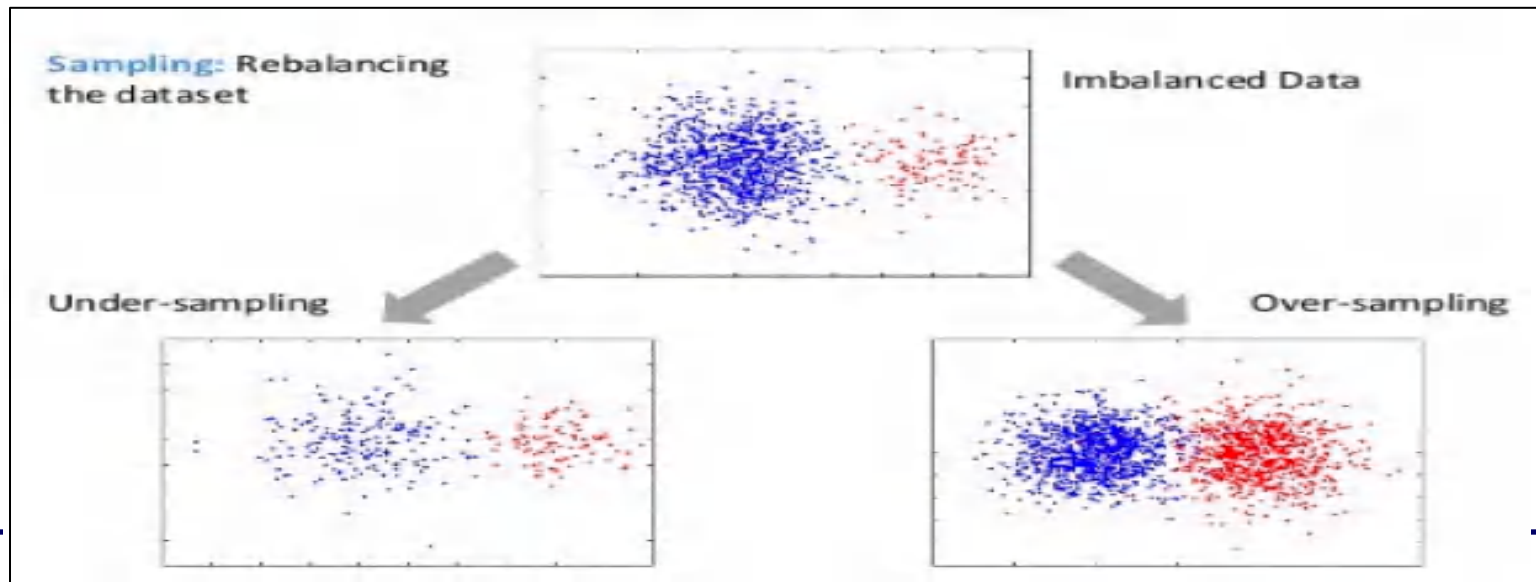
正负类比例

$$\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^-}{m^+}$$

- 将类别不平衡任务 变成 类别平衡任务 来解决
-

# 类别不平衡问题

- 再缩放方法（rescaling method）
  - 欠采样（under sampling）
    - 去除一些反例使正反例数目接近（EasyEnsemble [Liu et al.,2009]）
  - 过采样（over sampling）
    - 增加一些正例使正反例数目接近（SMOTE [Chawla et al.2002]）
  - 阈值移动（threshold-moving）



# 小结

---

- 线性模型引言
  - 回归任务
    - 掌握最小二乘法原理和推导
  - 二分类任务：
    - 熟悉对数几率回归、线性判别分析的建模原理
  - 多分类任务
    - 熟悉一对一、一对其余、多对多的原理
  - 类别不平衡任务
    - 了解处理类别不平衡问题的几种手法
-