


# 第六章 非线性规划

- 非线性规划问题及其数学模型
- 非线性规划解析解法
- 非线性规划数值解法
- 非线性规划与人工智能



# 非线性规划的解析解法

## ➤ 非线性规划问题及其数学模型

## ➤ 非线性规划解析解法

### □ 无约束极值问题

- 一阶条件
- 二阶条件

### □ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

## ➤ 凸规划

# 非线性规划的数学模型

$$\min f(\mathbf{x})$$


$$\text{s.t.} \quad h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

以求最小值为标准问题

# 非线性规划解的类型



■ **局部极小点**:  $\exists \varepsilon > 0$ , 满足  $f(\mathbf{x}^*) \leq f(\mathbf{x})$ ,  $\mathbf{x} \in N(\mathbf{x}^*, \varepsilon) \cap \text{可行域}$

■ **全局极小点 (最小点)**:  $f(\mathbf{x}^*) \leq f(\mathbf{x})$ ,  $\mathbf{x} \in \text{可行域}$

**严格极小点**: “<”

问题: 规划的目标是找哪一种极小点?

# 非线性规划的解析解

## ➤ 非线性规划问题及其数学模型

## ➤ 非线性规划解析解法

### □ 无约束极值问题

- 一阶条件
- 二阶条件

### □ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

## ➤ 凸规划

# 无约束极值问题

$$\min f(\mathbf{x}) \quad \mathbf{x} \in R^n$$

- 一阶极值条件（必要条件）
- 二阶极值条件（必要条件、充分条件）

# 一阶极值条件（必要条件）

驻点条件

$$\nabla f(\mathbf{x}^*) = \left[ \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right]^T \bigg|_{\mathbf{x}=\mathbf{x}^*} = \mathbf{0}$$

梯度

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f(\mathbf{x})}{\partial x_1} \\ \frac{\partial f(\mathbf{x})}{\partial x_2} \\ \vdots \\ \frac{\partial f(\mathbf{x})}{\partial x_n} \end{bmatrix}$$

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|)$$

# 梯度的几何性质

- $\nabla f(\mathbf{x})$  为目标函数 $f(\mathbf{x})$ 等值面在 $\mathbf{x}$ 的**法向量**
- $\nabla f(\mathbf{x})$ 是目标函数值 $f(\mathbf{x})$ 在 $\mathbf{x}$ 点**增长最快**的方向

证明：  $f(\mathbf{x} + \lambda \mathbf{p}) = f(\mathbf{x}) + \lambda \nabla f(\mathbf{x})^T \mathbf{p} + O(\lambda) \quad \|\mathbf{p}\|_2 = 1$

■ 方向导数（沿 $\mathbf{p}$ 方向的导数）：

$$D_{\mathbf{p}}(\mathbf{x}) = \lim_{\lambda \rightarrow 0} \frac{f(\mathbf{x} + \lambda \mathbf{p}) - f(\mathbf{x})}{\lambda} = \nabla f(\mathbf{x})^T \mathbf{p} = \|\nabla f(\mathbf{x})\|_2 \cos(\theta)$$



- $\mathbf{p}$ 取 $f(\mathbf{x})$ 等值面切方向时，  $\nabla f(\mathbf{x})^T \mathbf{p} = 0$
- $\mathbf{p}$ 取 $\nabla f(\mathbf{x})$ 时， 方向导数最大。



# 梯度图示

$$f(\mathbf{x}) = x_1^2 + x_2^2$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}$$



# Taylor公式的二阶展开

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \nabla^2 f(\mathbf{x}) \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|^2)$$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \dots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{bmatrix}$$

Hessian Matrix

二阶导数矩阵

# 矩阵的正定与负定

二次型:  $\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$   $\mathbf{A}$  为对称矩阵

$\forall \mathbf{x} \neq 0$   $\mathbf{x}^T \mathbf{A} \mathbf{x} > 0$   $\longrightarrow$   $\mathbf{A} > 0$  正定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0$   $\longrightarrow$   $\mathbf{A} \geq 0$  半正定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} < 0$   $\longrightarrow$   $\mathbf{A} < 0$  负定矩阵

$\mathbf{x}^T \mathbf{A} \mathbf{x} \leq 0$   $\longrightarrow$   $\mathbf{A} \leq 0$  半负定矩阵

# 二阶极值必要条件

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \nabla^2 f(\mathbf{x}) \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|^2)$$

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad \nabla^2 f(\mathbf{x}^*) \geq 0$$

局部极小值  $\Rightarrow$  “ $\geq$ ” 半正定

严格局部极小值  $\Rightarrow$  “ $>$ ” 正定


局部极大值  $\Rightarrow$  “ $\leq$ ” 半负定

严格局部极大值  $\Rightarrow$  “ $<$ ” 负定

仅为必要条件！

# 例1: Hesse矩阵为正定阵

$$f(\mathbf{x}) = x_1^2 + x_2^2$$




$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

## 例2：鞍点


$$f(\mathbf{x}) = x_1^2 - x_2^2$$



$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$$

### 例3：必要非充分



$$f(x) = x^3$$

$$\nabla f(x) = 3x^2$$

$$\nabla^2 f(x) = 6x$$

如果进一步满足 $x^*$ 邻域内的所有点的 $\nabla^2 f(x) \geq 0$ ，则 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*) \geq 0$ 是 $x^*$ 是极小值的充分条件。（应用不方便！）

# 二阶极值充分条件

$$f(\mathbf{x} + \Delta\mathbf{x}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \nabla^2 f(\mathbf{x}) \Delta\mathbf{x} + O(\|\Delta\mathbf{x}\|^2)$$

$$\nabla f(\mathbf{x}^*) = \mathbf{0} \quad \nabla^2 f(\mathbf{x}^*) > 0$$


“>” 正定  $\Rightarrow$  严格局部极小值

“<” 负定  $\Rightarrow$  严格局部极大值

“=” 需检验更高阶导数项



## 例4 充分非必要



$$\nabla f(0) = 0$$

$$\nabla^2 f(0) = 0$$

# 小结

无约束极小值问题的最优性条件

■ 一阶必要条件：（局部极小值/局部极大值）

$$\nabla f(x^*)=0$$

■ 二阶必要条件：（局部极小值）

$$\nabla f(x^*)=0 \text{ 且 } \nabla^2 f(x^*) \geq 0$$

■ 二阶充分条件：（严格局部极小值）

$$\nabla f(x^*)=0 \text{ 且 } \nabla^2 f(x^*) > 0$$

# 非线性规划的解析解

## ➤ 非线性规划问题及其数学模型

## ➤ 非线性规划解析解法

### □ 无约束极值问题

- 一阶条件
- 二阶条件

### □ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

## ➤ 凸规划

# 等式约束极值问题

$$\begin{array}{ll}\min & f(\mathbf{x}) \\ \text{s.t.} & h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m \\ & \mathbf{x} \in R^n\end{array}$$

$$\begin{array}{ll}\min & f(\mathbf{x}) \\ \text{s.t.} & \mathbf{h}(\mathbf{x}) = 0 \\ & \mathbf{x} \in R^n\end{array} \quad \mathbf{h}(\mathbf{x}) \triangleq \begin{bmatrix} h_1(\mathbf{x}) \\ \vdots \\ h_m(\mathbf{x}) \end{bmatrix}$$

# Lagrange函数法

定义Lagrange函数

$$\min L(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{h}(\mathbf{x}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i h_i(\mathbf{x})$$

$$\boldsymbol{\lambda} = [\lambda_1 \quad \lambda_2 \quad \cdots \quad \lambda_m]^T$$

求无约束极值问题:

$$\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\lambda})}{\partial \mathbf{x}} \right|_{\mathbf{x}^*} = \mathbf{0} \quad \longrightarrow \quad \nabla f(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i \nabla h_i(\mathbf{x}^*) = \mathbf{0}$$

$$\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\lambda})}{\partial \lambda} \right|_{\boldsymbol{\lambda}^*} = \mathbf{0} \quad \longrightarrow \quad h_i(\mathbf{x}^*) = 0 \quad i = 1, 2, \dots, m$$

# 非线性规划的解析解

## ➤ 非线性规划问题及其数学模型

## ➤ 非线性规划解析解法

### □ 无约束极值问题

- 一阶条件
- 二阶条件

### □ 有约束极值问题:

- 等式约束
- 不等式约束 (Kuhn-Tucker条件)
- 一般约束

## ➤ 凸规划

# 不等式约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

思考：能否如线性规划化为等式约束的问题？

# 求解思路

■ 直观思想：邻域内不存在可行的更优解

➤ 不存在同时满足以下两个条件的方向

- 可行点的可行方向
- 目标函数的下降方向

➤ 最优性条件

- **Fritz John**条件
- **Kuhn-Tucker**条件



# 可行方向

可行点 $\mathbf{x}^{(0)}$ 的可行方向 $\mathbf{p}$ 是 $\mathbf{x}^{(0)}$ 沿 $\mathbf{p}$ 方向移动无限小步后仍在可行域内的方向（约束函数值增大方向），数学上可表述为：

$\exists \lambda_0 > 0$ ，对于 $\forall \lambda \in (0, \lambda_0]$ ，有：

$$\mathbf{x}^{(0)} + \lambda \mathbf{p} \in \Omega, \quad \Omega = \{\mathbf{x} \mid g_j(\mathbf{x}) \geq 0, j = 1, 2, \dots, l\}$$

即 
$$g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) \geq 0 \quad j = 1, 2, \dots, l$$

# 可行方向判别条件（充分条件）

$$\nabla g_j(\mathbf{x}^{(0)})^T \mathbf{p} > 0 \quad \forall j \in J(\mathbf{x}^{(0)}) \quad J(\mathbf{x}^{(0)}) = \{j \mid g_j(\mathbf{x}^{(0)}) = 0, j = 1, 2, \dots, l\}$$

起作用约束集合

证明： 根据Taylor公式，有

$$g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) = g_j(\mathbf{x}^{(0)}) + \lambda \nabla g_j(\mathbf{x}^{(0)})^T \mathbf{p} + O(\lambda) \quad \|\mathbf{p}\| = 1$$

当 $\lambda$ 足够小时，如果  $j \notin J$ ，假设 $g_j(\mathbf{x})$ 连续，有

$$g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) \geq 0$$

如果， $j \in J$ ，当  $\nabla g_j(\mathbf{x}^{(0)})^T \mathbf{p} > 0$  时，也有

$$g_j(\mathbf{x}^{(0)} + \lambda \mathbf{p}) \geq 0$$

几何含义：与所有起作用约束梯度的夹角小于 $90^\circ$  的方向。

# 下降方向

定义：令目标函数值  $f(\mathbf{x}^{(0)})$  下降的方向，满足

$\exists \lambda_0 > 0$ ，对于  $\forall \lambda \in (0, \lambda_0]$ ，有  $f(\mathbf{x}^{(0)} + \lambda \mathbf{p}) < f(\mathbf{x}^{(0)})$

判别条件：  $\nabla f(\mathbf{x}^{(0)})^T \mathbf{p} < 0$  （充分条件）

证明：Taylor公式

$$f(\mathbf{x}^{(0)} + \lambda \mathbf{p}) = f(\mathbf{x}^{(0)}) + \lambda \nabla f(\mathbf{x}^{(0)})^T \mathbf{p} + O(\lambda)$$

几何含义：与目标函数的梯度夹角大于 $90^\circ$  的方向

# 局部极小值存在的直观条件


不存在可行下降方向 $\mathbf{p}$ ，即不存在同时满足下面两类不等式的方向。

$$\nabla f(\mathbf{x}^*)^T \mathbf{p} < 0$$


$$\nabla g_j(\mathbf{x}^*)^T \mathbf{p} > 0 \quad j \in J(\mathbf{x}^*) \quad J \text{为起作用约束集合}$$

几何含义：不存在与 $-\nabla f(\mathbf{x}^*)$ 和所有的 $\nabla g_{j \in J}(\mathbf{x}^*)$ 均成锐角的方向。

# 图示1：有可行下降方向



## 图示2：无可行下降方向



# Gordan引理

➤  $a_j$ 为一组已知向量，不存在向量 $p$ ，使

$$a_j^T p < 0 \quad j = 1, 2, \dots, l$$

同时成立的充要条件：

存在不全为零的非负实数 $\mu_j \geq 0$ ，使

$$\sum_{j=1}^l \mu_j a_j = 0 \quad \text{正线性相关 (positive linear dependence)}$$

几何含义： $a_j$ 不可能分布在任何超平面的同一侧

正线性相关 $\Rightarrow$ 线性相关

# Fritz John条件

➤ 若 $\mathbf{x}^*$ 是局部极小点，则存在不全为零的非负实数 $\mu_j \geq 0$ ， $j \in J(\mathbf{x}^*) \cup \{0\}$ ，使

$$\mu_0 \nabla f(\mathbf{x}^*) - \sum_{j \in J(\mathbf{x}^*)} \mu_j \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

证明：Gordan引理的直接推论

$$\nabla f(\mathbf{x}^*)^T \mathbf{p} < 0$$

$$-\nabla g_j(\mathbf{x}^*)^T \mathbf{p} < 0 \quad j \in J(\mathbf{x}^*)$$

问题：上述形式使用上是否方便？



# 等价Fritz John条件

➤ 若 $\mathbf{x}^*$ 是局部极小点，存在不全为零的非负实数 $\mu_j \geq 0$ ， $j=0,1,2,\dots,l$ ，使下列条件成立：

Fritz John条件

$$\left\{ \begin{array}{ll} \mu_0 \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j \nabla g_j(\mathbf{x}^*) = \mathbf{0} & \text{Lagrange函数驻点条件} \\ \mu_j g_j(\mathbf{x}^*) = 0 & j = 1, 2, \dots, l \quad \text{互补松弛条件} \\ \mu_j \geq 0 \quad \sum_{j=0}^l \mu_j \neq 0 & j = 0, 1, \dots, l \quad \text{强非负条件} \end{array} \right.$$

上述条件隐含了如下事实：

$$j \notin J(\mathbf{x}^*) \Rightarrow g_j(\mathbf{x}^*) > 0 \Rightarrow \mu_j = 0$$

# Kuhn-Tucker条件

- 若Fritz John条件的 $\mu_0 > 0$ ，则可推出KKT条件的数学形式：

$$\text{Kuhn-Tucker条件} \left\{ \begin{array}{ll} \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0} & \text{Lagrange驻点条件} \\ \mu_j^* g_j(\mathbf{x}^*) = 0 & j = 1, 2, \dots, l \quad \text{互补松弛条件} \\ \mu_j^* \geq 0 & j = 1, 2, \dots, l \quad \text{非负条件} \end{array} \right.$$

Karush(1939), Kuhn-Tucker (1951)

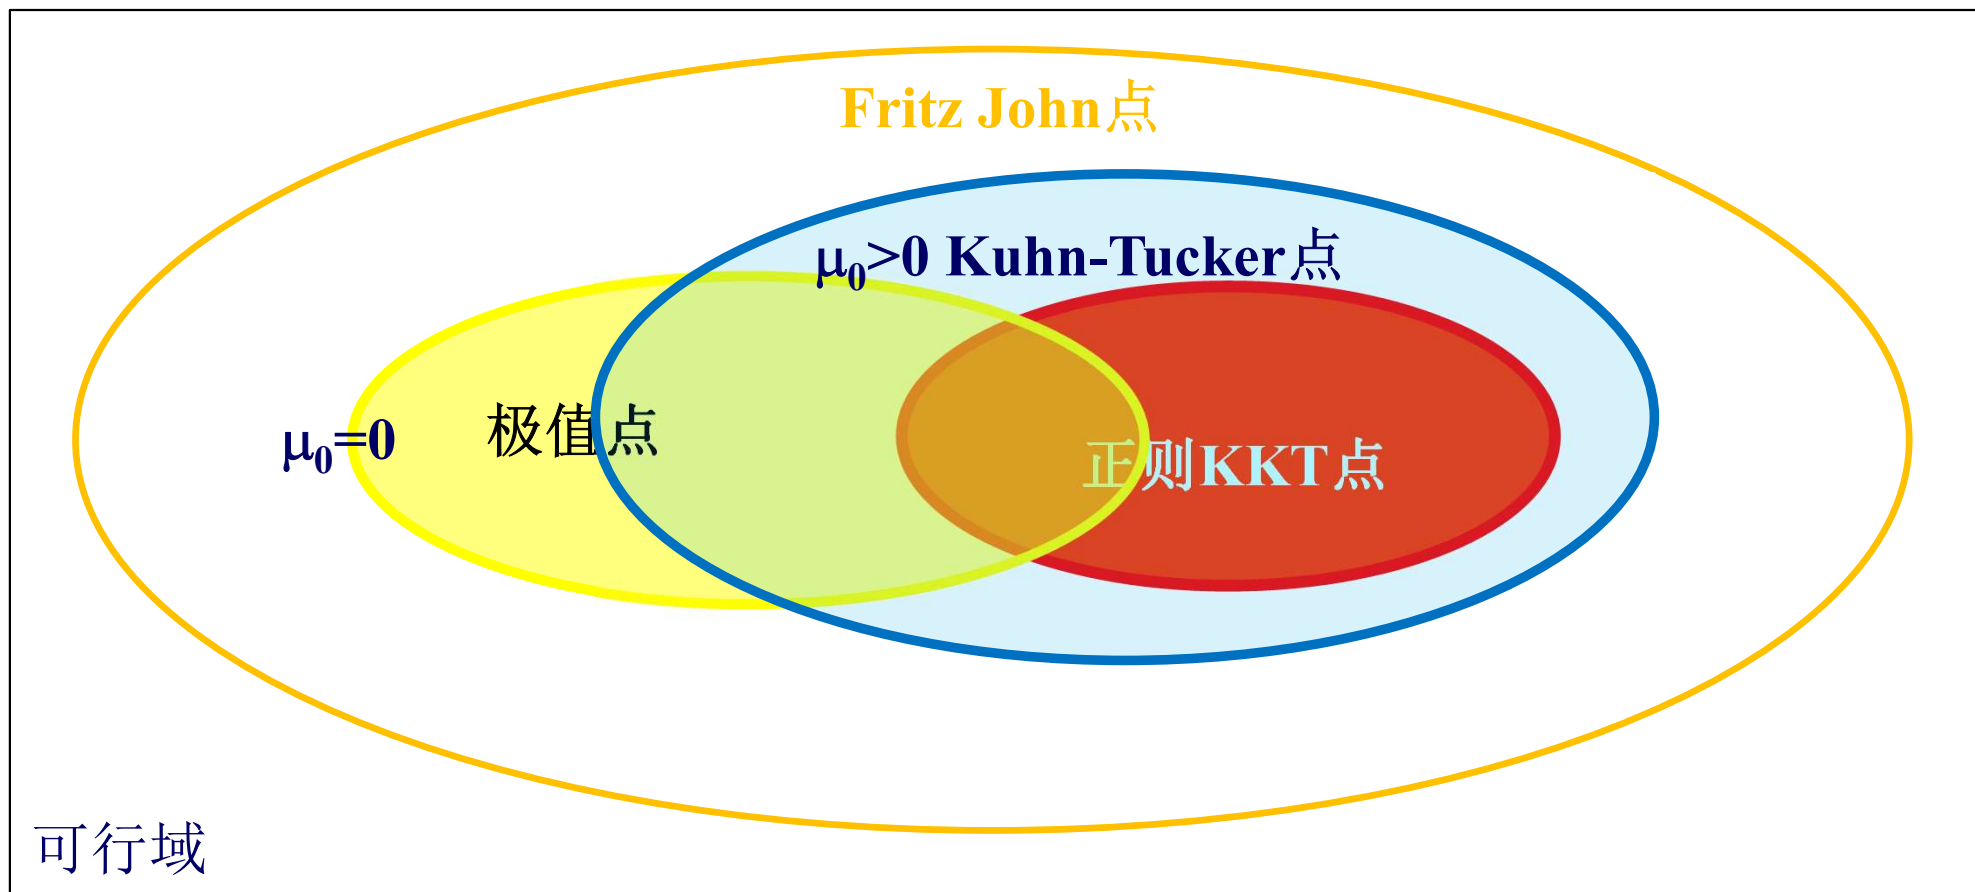
问题：什么条件下 $\mu_0 > 0$ ？

$$\mu_0 \nabla f(\mathbf{x}^*) - \sum_{j \in J(\mathbf{x}^*)} \mu_j \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

# 正则条件

- 正则条件(regular condition): 起作用约束 $\nabla g_{j \in J}(\mathbf{x})$ 线性无关。
- 性质: 若极小值 $\mathbf{x}^*$ 满足正则条件, 则KKT条件成立。  
证明:  $\mathbf{x}^*$ 满足正则条件, Fritz John条件中的 $\mu_0 > 0$ 。
- ◆ Kuhn-Tucker定理: 若 $\mathbf{x}^*$ 是局部极小点, 且满足正则条件[约束规格], 则Kuhn-Tucker条件成立。
- 约束规格(constraint qualification): 使结论成立的某种前提。  
注意: 约束规格不唯一, 正则条件只是其中之一。

# 集合关系



# 非线性规划的解析解

## ➤ 非线性规划问题及其数学模型

## ➤ 非线性规划解析解法

### □ 无约束极值问题

- 一阶条件
- 二阶条件

### □ 有约束极值问题:

- 等式约束
- 不等式约束 (Kuhn-Tucker条件)
- 一般约束

## ➤ 凸规划

# 一般约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

求解思路：化为不等式约束极值问题

# 等价不等式约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad h_i(\mathbf{x}) \geq 0 \quad i = 1, 2, \dots, m$$

$$-h_i(\mathbf{x}) \geq 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

# Fritz John条件推导

➤ 根据不等式约束Fritz John条件，有

$$\mu_0^* \nabla f(\mathbf{x}^*) - \sum_{i=1}^m \mu_i' \nabla h_i(\mathbf{x}^*) + \sum_{i=1}^m \mu_i'' \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$



$$\mu_0^* \nabla f(\mathbf{x}^*) - \sum_{i=1}^m (\mu_i' - \mu_i'') \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$



$$\mu_0^* \nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

$$\mu_i' \geq 0 \quad \mu_i'' \geq 0 \quad \longrightarrow \quad \gamma_i^* = \mu_i' - \mu_i'' \text{ 无符号约束} \quad i = 1, 2, \dots, p$$

注意  $\mu_0$ 、 $\mu_j$ 、 $\gamma_i$  不可同时为 **0** !



# 一般约束下的Fritz John条件

➤ 若 $\mathbf{x}^*$ 是局部极小点，存在不全为零的 $\mu_j$  ( $j=0,1,2,\dots,m$ )和 $\gamma_i$  ( $i=0,1,2,\dots,p$ )，满足

$$\mu_0^* \nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0} \quad \text{稳定性条件}$$

$$\mu_j^* g_j(\mathbf{x}^*) = 0 \quad j = 1, 2, \dots, m$$

互补松弛条件

$$\mu_j^* \geq 0 \quad j = 0, 1, \dots, m$$

$$\sum_{j=0}^l \mu_j^* + \sum_{i=1}^m |\gamma_i^*| \neq 0$$

强非负条件

$$\gamma_i^* h_i(\mathbf{x}^*) = 0 \quad i = 1, 2, \dots, p$$

等式互补松弛条件

等式约束自然满足

# 一般约束下的KKT条件

- 若 $\mathbf{x}^*$ 是局部极小点，等式约束梯度 $\nabla h_i(\mathbf{x}^*)$ 和起作用约束梯度 $\nabla g_j(\mathbf{x}^*)$ 线性无关，则下列条件成立：

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0} \quad \text{Lagrange驻点条件}$$

$$\mu_j^* g_j(\mathbf{x}^*) = 0 \quad j = 1, 2, \dots, l \quad \text{互补松弛条件}$$

$$\mu_j^* \geq 0 \quad j = 1, 2, \dots, l \quad \text{非负条件}$$

# 广义Lagrange函数法

定义Lagrange函数

$$L(\mathbf{x}, \boldsymbol{\gamma}, \boldsymbol{\mu}) = f(\mathbf{x}) - \sum_{i=1}^m \gamma_i h_i(\mathbf{x}) - \sum_{j=1}^l \mu_j g_j(\mathbf{x})$$

$\gamma_i^*$ 和 $\mu_j^*$ 称为广义Lagrange乘子

类似无约束极值问题，得到：

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

Lagrange驻点条件

$$\mu_j^* g_j(\mathbf{x}^*) = 0 \quad j = 1, 2, \dots, l$$

互补松弛条件

$$\mu_j^* \geq 0 \quad j = 1, 2, \dots, l$$

非负条件

$$h_i(\mathbf{x}^*) = 0 \quad i = 1, 2, \dots, m$$

可行性条件

$$g_j(\mathbf{x}^*) \geq 0 \quad j = 1, 2, \dots, l$$

# KKT条件的矩阵形式

$$\boldsymbol{\gamma}^* = \begin{bmatrix} \gamma_1^* \\ \gamma_2^* \\ \vdots \\ \gamma_m^* \end{bmatrix} \quad \boldsymbol{h}(\boldsymbol{x}) = \begin{bmatrix} h_1(\boldsymbol{x}) \\ h_2(\boldsymbol{x}) \\ \vdots \\ h_m(\boldsymbol{x}) \end{bmatrix} \quad \boldsymbol{\mu}^* = \begin{bmatrix} \mu_1^* \\ \mu_2^* \\ \vdots \\ \mu_l^* \end{bmatrix} \quad \boldsymbol{g}(\boldsymbol{x}) = \begin{bmatrix} g_1(\boldsymbol{x}) \\ g_2(\boldsymbol{x}) \\ \vdots \\ g_l(\boldsymbol{x}) \end{bmatrix}$$

$$\nabla \boldsymbol{h}(\boldsymbol{x}) = [\nabla h_1(\boldsymbol{x}) \quad \nabla h_2(\boldsymbol{x}) \quad \cdots \quad \nabla h_m(\boldsymbol{x})]$$
$$\nabla \boldsymbol{g}(\boldsymbol{x}) = [\nabla g_1(\boldsymbol{x}) \quad \nabla g_2(\boldsymbol{x}) \quad \cdots \quad \nabla g_l(\boldsymbol{x})] = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_2}{\partial x_1} & \cdots & \frac{\partial g_l}{\partial x_1} \\ \frac{\partial g_1}{\partial x_2} & \frac{\partial g_2}{\partial x_2} & \cdots & \frac{\partial g_l}{\partial x_2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_1}{\partial x_n} & \frac{\partial g_2}{\partial x_n} & \cdots & \frac{\partial g_l}{\partial x_n} \end{bmatrix} = \left( \frac{\partial \boldsymbol{g}(\boldsymbol{x})}{\partial \boldsymbol{x}} \right)^T$$

梯度矩阵与雅可比矩阵是转置关系

# KKT条件的矩阵形式

$$\nabla f(\mathbf{x}^*) - \nabla h(\mathbf{x}^*)\gamma^* - \nabla g(\mathbf{x}^*)\mu^* = \mathbf{0} \quad \text{Lagrange驻点条件}$$

$$\mu^* \odot g(\mathbf{x}^*) = \mathbf{0} \quad \longleftrightarrow \quad \mu_j^* g_j(\mathbf{x}^*) = 0 \quad j = 1, 2, \dots, l$$

*Hadamard product*

$$\mu^* \geq 0$$

非负条件

互补松弛条件

$$h(\mathbf{x}^*) = \mathbf{0}$$

可行性条件

$$g(\mathbf{x}^*) \geq \mathbf{0}$$


# 举例

$$\min f(x_1, x_2) = (x_1 - 2)^2 + x_2^2$$

$$\text{s.t. } x_2 \leq x_1 + 2$$

$$x_2 \geq x_1^2 + 1$$

$$x_1 \geq 0 \quad x_2 \geq 0$$



# 目标函数、约束函数

$$f(\mathbf{x}) = (x_1 - 2)^2 + x_2^2$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2(x_1 - 2) \\ 2x_2 \end{bmatrix}$$

$$\mathbf{g}(\mathbf{x}) = \begin{bmatrix} x_1 - x_2 + 2 \\ -x_1^2 + x_2 - 1 \\ x_1 \\ x_2 \end{bmatrix}$$

$$\nabla \mathbf{g}(\mathbf{x}) = \begin{bmatrix} 1 & -2x_1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{bmatrix}$$

# KKT条件的矩阵形式

$$\nabla f(\mathbf{x}^*) - \nabla h(\mathbf{x}^*)\gamma^* - \nabla g(\mathbf{x}^*)\boldsymbol{\mu}^* = \mathbf{0}$$

$$\Rightarrow \begin{bmatrix} 2(x_1 - 2) \\ 2x_2 \end{bmatrix} - \begin{bmatrix} 1 & -2x_1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\boldsymbol{\mu}^* \odot \mathbf{g}(\mathbf{x}^*) = \mathbf{0} \Rightarrow \begin{bmatrix} \mu_1 (x_1 - x_2 + 2) \\ \mu_2 (-x_1^2 + x_2 - 1) \\ \mu_3 x_1 \\ \mu_4 x_2 \end{bmatrix} = \mathbf{0}$$

$$\mathbf{g}(\mathbf{x}^*) \geq \mathbf{0} \quad \boldsymbol{\mu}^* \geq \mathbf{0}$$



# KKT条件的代数形式

$$2(x_1 - 2) - \mu_1 + 2\mu_2 x_1 - \mu_3 = 0$$

$$2x_2 + \mu_1 - \mu_2 - \mu_4 = 0$$

$$\mu_1(x_1 - x_2 + 2) = 0$$

$$\mu_2(-x_1^2 + x_2 - 1) = 0$$

$$\mu_3 x_1 = 0$$

$$\mu_4 x_2 = 0$$

6个变量、6个方程


$$\mu_j \geq 0 \quad j = 1, 2, 3, 4$$

$$x_2 \leq x_1 + 2 \quad x_1 \geq 0$$

$$x_2 \geq x_1^2 + 1 \quad x_2 \geq 0$$

不等式条件

# 图示



# 求解

观察可得:  $\mu_1 = \mu_3 = \mu_4 = 0$

所以有:  $(1 + \mu_2)x_1 - 2 = 0$

$$2x_2 - \mu_2 = 0$$

$$-x_1^2 + x_2 - 1 = 0$$

求解得:  $\mu_2^* = 2.6219 \quad x_1^* = 0.5536 \quad x_2^* = 1.3064$

$$f(\mathbf{x}^*) = 3.7989$$

# 非线性规划的解析解

## ➤ 非线性规划问题及其数学模型

## ➤ 非线性规划解析解法

### □ 无约束极值问题

- 一阶条件
- 二阶条件

### □ 有约束极值问题:

- 等式约束
- 不等式约束 (**Kuhn-Tucker**条件)
- 一般约束

## ➤ 凸规划

# 凸规划

$$\min f(\mathbf{x}) \quad \text{凸函数}$$

$$\text{s.t. } h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m \quad \text{线性函数}$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l \quad \text{凹函数}$$

$$\mathbf{x} \in R^n$$

# 凸函数与凹函数

- 凸函数为满足下列条件的函数：


$$f[\lambda \mathbf{x}_1 + (1-\lambda)\mathbf{x}_2] \leq \lambda f(\mathbf{x}_1) + (1-\lambda)f(\mathbf{x}_2) \quad 0 < \lambda < 1 \quad \mathbf{x}_1, \mathbf{x}_2 \in R^n$$

- “<”：严格凸函数
- “≥”：凹函数
- “>”：严格凹函数


注意：线性函数既是凸函数，又是凹函数，所以线性规划是凸规划。

# 凸函数和凹函数图示


凸函数



凹函数



非凸非凹函数



# 凸函数判定条件（充要条件）

- 一阶条件

$$\forall \mathbf{x}_1, \mathbf{x}_2 \in R^n \quad \text{恒有} \quad f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1)$$

几何意义：任何一点的切线在凸函数曲线的下方

- 二阶条件

$$\forall \mathbf{x} \in R^n \quad \text{恒有} \quad \nabla^2 f(\mathbf{x}) \geq 0$$

几何意义：函数曲线向上弯曲

- “>”：严格凸函数
- “≤”：凹函数
- “<”：严格凹函数
- “=”：线性函数



$$\left[ \frac{d(\mathbf{k}^T \mathbf{x})}{d\mathbf{x}} \right]^T = \mathbf{k} \quad \left[ \frac{d(\mathbf{x}^T \mathbf{A} \mathbf{x})}{d\mathbf{x}} \right]^T = 2\mathbf{A}\mathbf{x} \quad \mathbf{A} \text{ 对称}$$

# 二次函数为凸函数的充要条件

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{c}^T \mathbf{x} + r \quad \mathbf{H} \text{ 为对称矩阵}$$

$$\nabla f(\mathbf{x}) = \mathbf{H} \mathbf{x} + \mathbf{c}$$

$$\nabla^2 f(\mathbf{X}) = \mathbf{H} \geq 0 \quad \mathbf{H} \text{ 为半正定矩阵}$$

$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1)$$

# 凸函数的性质

- 凸函数非负线性组合仍为凸函数

$$\gamma_1 f_1(\mathbf{x}) + \gamma_2 f_2(\mathbf{x}) \quad \gamma_i \geq 0$$

- 若 $f(\mathbf{x})$ 是定义在凸集 $R_C$ 上的凸函数, 则其 $\beta$ 水平集 $S_\beta$ 为凸集。

$$S_\beta = \{\mathbf{x} \mid f(\mathbf{x}) \leq \beta, \mathbf{x} \in R_C\} \quad \beta\text{水平集}$$

- 对于凸函数 $f(\mathbf{x})$ , 若存在 $\mathbf{x}^* \in R^n$ 满足

$$\nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \geq 0 \quad \forall \mathbf{x} \in R^n \quad \text{充要条件!}$$

则 $\mathbf{x}^*$ 为 $f(\mathbf{x})$ 的全局最小点。

推论1: 对于凸目标函数,  $\nabla f(\mathbf{x}^*)=0$  是 $\mathbf{x}^*$ 为极小值的充要条件。

推论2: 对于凸目标函数, 局部极小点( $\nabla f(\mathbf{x}^*)=0$ )也是全局最小点。

# 凸集性质

- 凸规划的可行域为凸集

$$h_i(\mathbf{x}) = 0 \quad -g_j(\mathbf{x}) \leq 0$$

各约束的0水平集为凸集

凸集的交集为凸集

- 如果最优解存在，最优解集合也为凸集

$$f[\lambda \mathbf{x}_1^* + (1-\lambda)\mathbf{x}_2^*] \leq \lambda f(\mathbf{x}_1^*) + (1-\lambda)f(\mathbf{x}_2^*) = f(\mathbf{x}_1^*) = f(\mathbf{x}_2^*) \quad 0 < \lambda < 1$$

➡  $f[\lambda \mathbf{x}_1^* + (1-\lambda)\mathbf{x}_2^*] = f(\mathbf{x}_1^*) = f(\mathbf{x}_2^*)$  最优解的连线段均为最优解

推论：线性规划问题的最优解集为所有最优顶点构成的多边形。（归纳法证）

$$\mathbf{x}^* = \sum_{i=1}^r a_i \mathbf{x}_i^* \quad \sum_{i=1}^r a_i = 1 \quad 0 \leq a_i \leq 1 \quad i = 1, \dots, r$$

# 凸规划性质

- 任何局部极值解也是全局最优解 （目标函数为凸函数）

局部极小点和全局最小点连线的目标函数值相同

- 若目标函数为严格凸函数，则如果全局最优解存在，必为唯一全局最优解。（反证法）

$$f[\lambda \mathbf{x}_1^* + (1-\lambda)\mathbf{x}_2^*] < \lambda f(\mathbf{x}_1^*) + (1-\lambda)f(\mathbf{x}_2^*) = f(\mathbf{x}_1^*) = f(\mathbf{x}_2^*)$$

最优解的唯一性为数值解法提供了方便。

- 凸规划下的KKT条件为最优解的充要条件

# KT条件的充分性证明

$$\nabla f(\mathbf{x}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = 0 \quad \mu_j^* g_j(\mathbf{x}^*) = 0 \quad \mu_j^* \geq 0$$

$$\begin{aligned} f(\mathbf{x}) \text{ 是凸函数} &\Rightarrow f(\mathbf{x}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \\ &= f(\mathbf{x}^*) + \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) + \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \end{aligned}$$

$$h_i(\mathbf{x}) \text{ 线性函数且 } h_i(\mathbf{x}) = 0 \Rightarrow \nabla h_i(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) = h_i(\mathbf{x}) - h_i(\mathbf{x}^*) = 0$$

$$g_j(\mathbf{x}) \text{ 是凹函数} \Rightarrow \nabla g_j(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) \geq g_j(\mathbf{x}) - g_j(\mathbf{x}^*)$$

根据互补松弛性条件  $\mu_j^* g_j(\mathbf{x}^*) = 0$  且  $g_j(\mathbf{x}) \geq 0$ ，有

$$f(\mathbf{x}) \geq f(\mathbf{x}^*) + \sum_{j=1}^l \mu_j^* [g_j(\mathbf{x}) - g_j(\mathbf{x}^*)] = f(\mathbf{x}^*) + \sum_{j=1}^l \mu_j^* g_j(\mathbf{x}) \geq f(\mathbf{x}^*)$$

# 举例


$$\min f(x_1, x_2) = (x_1 - 2)^2 + x_2^2$$

$$\text{s.t. } x_2 \leq x_1 + 2$$

$$x_2 \geq x_1^2 + 1$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$



# 凸规划判断

$$f(\mathbf{x}) = (x_1 - 2)^2 + x_2^2 \Rightarrow \nabla f(\mathbf{x}) = \begin{bmatrix} 2(x_1 - 2) \\ 2x_2 \end{bmatrix} \Rightarrow \nabla^2 f(\mathbf{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} > 0$$

$$g_1(\mathbf{x}) = x_1 - x_2 + 2 \Rightarrow \nabla g_1(\mathbf{x}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \Rightarrow \nabla^2 g_1(\mathbf{x}) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

$$g_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \Rightarrow \nabla g_2(\mathbf{x}) = \begin{bmatrix} -2x_1 \\ 1 \end{bmatrix} \Rightarrow \nabla^2 g_2(\mathbf{x}) = \begin{bmatrix} -2 & 0 \\ 0 & 0 \end{bmatrix} \leq 0$$

$$g_3(\mathbf{x}) = x_1 \Rightarrow \nabla g_3(\mathbf{x}) = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \Rightarrow \nabla^2 g_3(\mathbf{x}) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

$$g_4(\mathbf{x}) = x_2 \Rightarrow \nabla g_4(\mathbf{x}) = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \Rightarrow \nabla^2 g_4(\mathbf{x}) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

# 小结

## ➤ 无约束优化问题

### □ 目标函数为凸函数

- $\nabla f(x^*)=0$  是极小值的充要条件
- 局部极小值为全局极小值

### □ 目标函数为严格凸函数

- 局部极小值为唯一的极小值

## ➤ 凸规划

- KKT条件为极小值的充要条件
- 局部极小值为全局极小值



# 非线性规划的matlab求解

- 线性规划(LP): **linprog**
  - 混合整数线性规划 (MILP): **intlinprog**
  - 二次规划(QP): **quadprog**
  - 二阶锥规划(SOCP): **coneprog**
  - 半定规划(SDP): **Yalmip**中调用SDP求解器
- 
- 无约束极值问题: **fminunc**
  - 有约束极值问题: **fmincon**

**LPs  $\subset$  QPs  $\subset$  QCQPs  $\subset$  SOCPs  $\subset$  SDPs  $\subset$  锥规划CPs**

# 二次规划

- (凸) 二次规划 (QP, Quadratic Program) :

$$\min \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{q}^T \mathbf{x} + r$$


s.t.

$$\mathbf{G} \mathbf{x} \leq \mathbf{h}$$

$$\mathbf{A} \mathbf{x} = \mathbf{b}$$

$$\mathbf{x} \in \mathbb{R}^n$$

线性约束



$$\mathbf{P} \in S_{+}^n \quad \mathbf{G} \in \mathbb{R}^{l \times n} \quad \mathbf{A} \in \mathbb{R}^{m \times n}$$

半正定对称矩阵集合

LPs  $\subset$  QPs

# 二次约束二次规划

## ■ 二次约束二次规划问题

(QCQP, Quadratically Constrained Quadratic Program):

$$\min \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{q}^T \mathbf{x} + r$$

$$\text{s.t. } \frac{1}{2} \mathbf{x}^T \mathbf{P}_j \mathbf{x} + \mathbf{q}_j^T \mathbf{x} + r_j \leq 0 \quad j = 1, \dots, l$$

$$\mathbf{A} \mathbf{x} = \mathbf{b}$$

$$\mathbf{x} \in R^n$$

线性约束

$$\mathbf{P}, \mathbf{P}_j \in S_{+}^n$$

$$\mathbf{A} \in R^{m \times n}$$

QPs  $\subset$  QCQPs

# 二阶锥规划

- 二阶锥规划问题  
(SOCP, Second-Order Cone Program):

$$\min \mathbf{c}^T \mathbf{x}$$

$$\text{s.t.} \quad \| \mathbf{A}_j \mathbf{x} + \mathbf{b}_j \|_2 \leq \mathbf{c}_j^T \mathbf{x} + d_j \quad j = 1, \dots, l$$

二阶锥约束

$$\mathbf{F}\mathbf{x} = \mathbf{g}$$

$$\mathbf{x} \in R^n$$

# 半定规划

■ 半定规划（SDP, Semidefinite program）:

□ LMI标准模型:

$$\min \mathbf{c}^T \mathbf{x}$$

$$\text{s.t. } x_1 \mathbf{F}_1 + \cdots + x_n \mathbf{F}_n + \mathbf{G} \preceq 0$$

线性矩阵不等式

LMI(linear matrix inequality)

$$\mathbf{A}\mathbf{x} = \mathbf{b}$$

$$\mathbf{A} \succeq \mathbf{B} \Leftrightarrow \mathbf{A} - \mathbf{B} \text{ 半正定}$$

$$\mathbf{x} \in \mathbb{R}^n$$

$$\mathbf{G}, \mathbf{F}_j \in \mathcal{S}^k \quad \mathbf{A} \in \mathbb{R}^{p \times n}$$

半定规划可视为线性规划在矩阵参数空间的推广！