

# 第六章 非线性规划

## ➤ 非线性规划数值解法

### □ 无约束极值问题


#### ● 下降迭代法

### □ 有约束极值问题

#### ● 可行方向法

#### ● 制约函数法

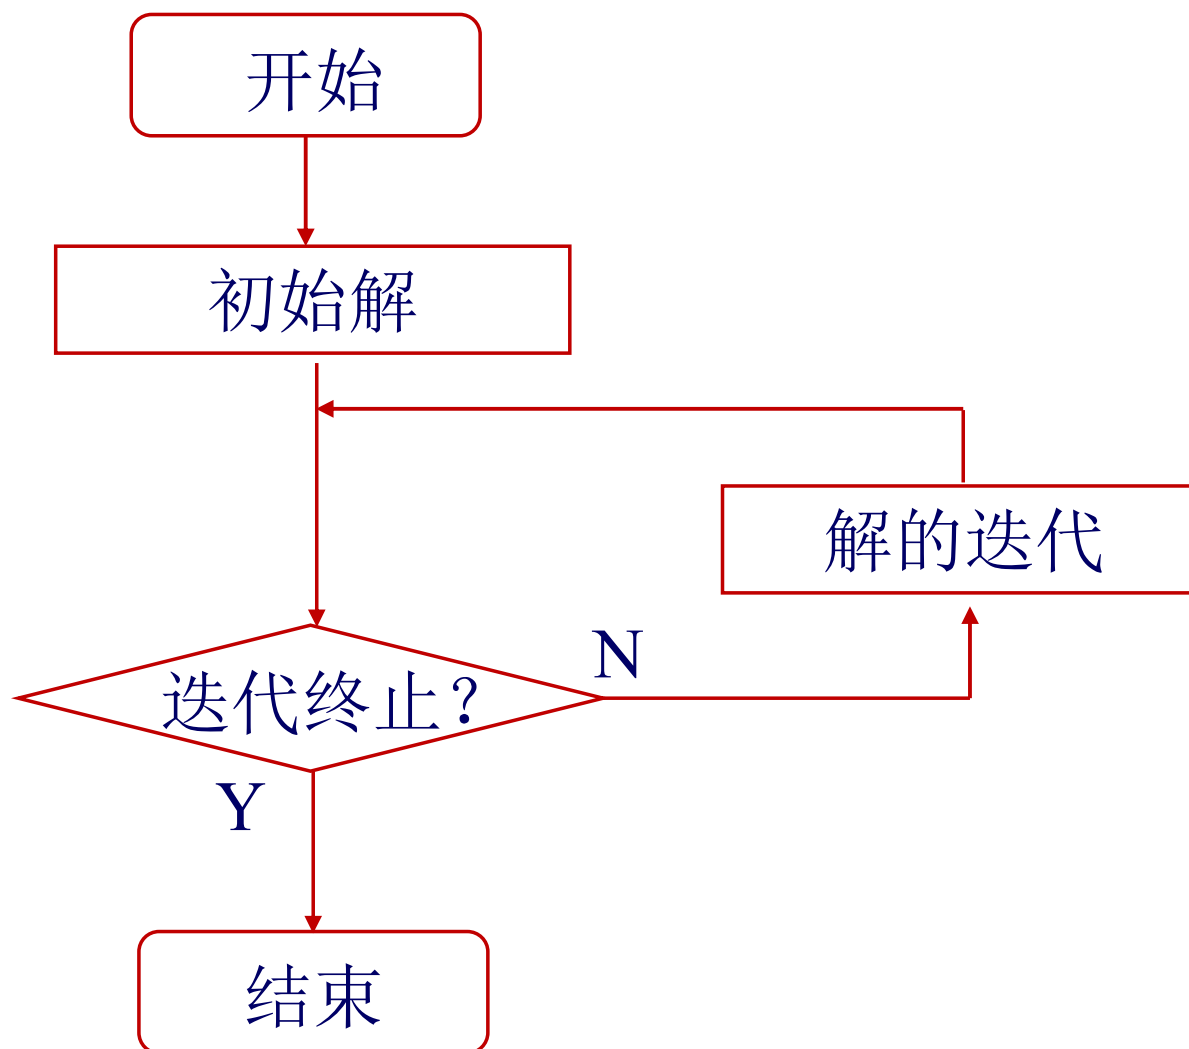
#### ● 逐次逼近法



# 数值求解的一般思路

- 思想
  - 迭代法
- 方法类型
  - 基于梯度的方法
  - 非梯度的方法（直接法、启发式方法）
- 问题种类
  - 无约束极值问题
  - 有约束极值问题

# 数值解法的流程图



# 下降迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \quad \Rightarrow \quad f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$$

## ➤ 迭代方向

### ■ 基于梯度方法

□ 最速下降法

□ 牛顿法

□ 拟牛顿法

□ 共轭梯度法

■ 直接法

## ➤ 步长选择（一维搜索）

■ 基于梯度法

■ 直接法

## ➤ 迭代终止准则

# 1、最速下降法

■ 设计思想：使目标函数值下降

目标函数值： $f(\mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}) = f(\mathbf{x}^{(k)}) + \lambda_k \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + O(\lambda_k)$

可选方向： $\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} = \|\nabla f(\mathbf{x}^{(k)})\|_2 \cdot \|\mathbf{p}^{(k)}\|_2 \cos \theta < 0$  （方向导数）

下降最快方向： $\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)})$  负梯度方向

性质：最优步长时  $\nabla f(\mathbf{x}^{(k+1)}) \perp \nabla f(\mathbf{x}^{(k)})$

优点：计算量小。

缺点：“之”字迭代路径，接近极值点时尤为严重。

应用场合：迭代前期。

# 极小值点附近的等值面

$$f(\mathbf{x}) = f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*) + O(\|\mathbf{x} - \mathbf{x}^*\|^2)$$

极值点:  $\nabla f(\mathbf{x}^*) = 0 \longrightarrow f(\mathbf{x}) = f(\mathbf{x}^*) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*) + O(\|\mathbf{x} - \mathbf{x}^*\|^2)$

极值点附近等值面  $\longrightarrow f(\mathbf{x}) = c \approx f(\mathbf{x}^*) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*)$   
 $\mathbf{x}^{(k)} \in N(\mathbf{x}^*, \varepsilon) \quad f(\mathbf{x}) = c$

$$\longrightarrow (\mathbf{x} - \mathbf{x}^*)^T \nabla^2 f(\mathbf{x}^*) (\mathbf{x} - \mathbf{x}^*) \approx c' = 2[c - f(\mathbf{x}^*)]$$

严格极小点:  $\nabla^2 f(\mathbf{x}^*) > 0 \longrightarrow \mathbf{x}^*$ 为中心的椭球面

极小点:  $\nabla^2 f(\mathbf{x}^*) \geq 0 \longrightarrow$ 降维椭球面

问题: 如何加速极值点附近的迭代?

$$h(\mathbf{x}) = g[f(\mathbf{x})]$$

$$\nabla_{\mathbf{x}} h(\mathbf{x}) = \nabla_{\mathbf{x}} f(\mathbf{x}) \nabla_f g[f(\mathbf{x})]$$

$$\left[ \frac{d(\mathbf{k}^T \mathbf{x})}{d\mathbf{x}} \right]^T = \mathbf{k}$$

$$\left[ \frac{d(\mathbf{x}^T \mathbf{A} \mathbf{x})}{d\mathbf{x}} \right]^T = 2\mathbf{A}\mathbf{x}$$

## 2、牛顿法

■ 设计思想：近似为二次问题。

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

驻点条件  $\longrightarrow \nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(k)}) + \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)}) \approx 0$

迭代公式  $\longrightarrow \mathbf{x}^{(k+1)} \approx \mathbf{x}^{(k)} - [\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$

迭代方向  $\longrightarrow \mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$  牛顿方向

优点：极值点附近收敛速率快。

缺点：计算量大，需要求二阶导数和Hessian矩阵逆。

远离极值点时，不一定是下降方向，需采用进一步修正。

应用场合：二次目标函数或极值点附近。

# 二次函数的极小点

■ 设 $A$ 为对称矩阵，二次函数  $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$

● 驻点方程：  $\nabla f(\bar{\mathbf{x}}) = A\bar{\mathbf{x}} + \mathbf{b} = 0$

□ 有解：  $\text{rank} A = \text{rank}[A \ \mathbf{b}]$

□ 无解：  $\text{rank} A \neq \text{rank}[A \ \mathbf{b}]$

➤ **Hessian**矩阵：  $\nabla^2 f(\mathbf{x}) = A$

例：抛物面

(1)  $A > 0$  椭球面：  $\mathbf{x}^* = A^{-1}\mathbf{b}$  唯一极小点

$$f(\mathbf{x}) = x_1^2 + x_2 + c$$

无界解（无驻点解）

(2)  $A \geq 0$  &  $\text{rank} A < n$  椭球柱面/平行超平面：

$$f(\mathbf{x}) = x_1^2 \text{ 无穷多个极小点}$$

(3)  $A \leq 0$  （降维）椭球面： 无界解（极大点）

(4)  $A$ 不定 （高维）马鞍面：  $f(\mathbf{x}) = x_1^2 - x_2^2$  无界解（鞍点解）

问题：如何修正牛顿法的迭代方向？



# Levenberg-Marquardt修正

- 设计思想：将  $\nabla^2 f(\mathbf{x}^{(k)})$  变为正定矩阵，保证  $\mathbf{p}$  是下降方向

**L-M修正方向：**  $\mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)}) + \mu_k \mathbf{I}]^{-1} \nabla f(\mathbf{x}^{(k)})$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - [\nabla^2 f(\mathbf{x}^{(k)}) + \mu_k \mathbf{I}]^{-1} \nabla f(\mathbf{x}^{(k)})$$

$\mu_k > |\lambda_{\min}^-|$      $\lambda_{\min}^-$  为  $\nabla^2 f(\mathbf{x}^{(k)})$  最小负特征值

$\mu \rightarrow 0$ :    牛顿法

$\mu \rightarrow \infty$ :    最速下降法

如果不求特征值，可以从较小的  $\mu$  值试探

# 3、拟牛顿法

- 设计思想：数值法求Hessian矩阵的逆。

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k+1)}) + \nabla f(\mathbf{x}^{(k+1)})^T (\mathbf{x} - \mathbf{x}^{(k+1)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k+1)})^T \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)})$$

在 $\mathbf{x}^{(k+1)}$ 展开

求导  $\longrightarrow$

$$\nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)})$$

$\mathbf{x} = \mathbf{x}^{(k)}$   $\longrightarrow$

$$\nabla f(\mathbf{x}^{(k)}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)})$$

Hessian矩阵的数值关系

$\longrightarrow$

$$\nabla f(\mathbf{x}^{(k)}) - \nabla f(\mathbf{x}^{(k+1)}) \approx \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)})$$

Hessian逆的数值关系

$\longrightarrow$

$$\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \approx [\nabla^2 f(\mathbf{x}^{(k+1)})]^{-1} [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]$$

$$\delta_k \triangleq \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$$

$$\mathbf{H}_k \approx [\nabla^2 f(\mathbf{x}^{(k)})]^{-1}$$

$$\gamma_k \triangleq \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$$



$$\delta_k = \mathbf{H}_{k+1} \gamma_k$$

拟牛顿条件

# 变尺度法

◆ 目标：数值法求解**Hessian**矩阵的逆

由**Davidon**提出，**Fletcher**和**Powell**改进，也称**DFP**算法。

迭代方向： $\mathbf{p}^{(k)} = -\mathbf{H}_k \nabla f(\mathbf{x}^{(k)})$   $\mathbf{p}^{(k)} = -[\nabla^2 f(\mathbf{x}^{(k)})]^{-1} \nabla f(\mathbf{x}^{(k)})$

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \Delta \mathbf{H}_k \quad \mathbf{H}_1 = \mathbf{I}$$

$$\Delta \mathbf{H}_k = \frac{\boldsymbol{\delta}_k \boldsymbol{\delta}_k^T}{\boldsymbol{\delta}_k^T \boldsymbol{\gamma}_k} - \frac{\mathbf{H}_k \boldsymbol{\gamma}_k \boldsymbol{\gamma}_k^T \mathbf{H}_k}{\boldsymbol{\gamma}_k^T \mathbf{H}_k \boldsymbol{\gamma}_k}$$

$$\boldsymbol{\delta}_k \triangleq \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$$

$$\boldsymbol{\gamma}_k \triangleq \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$$

可以证明：1、 $\mathbf{H}_k$ 满足拟牛顿条件，为**Hessian**矩阵的逆。

2、当目标函数为严格凸二次函数时，可经有限步迭代收敛于极值（二次终止性）。为什么不是1步？

## 4、共轭梯度法

■ 共轭方向定义：若 $A$ 正定，且 $p^{(1)}$ 和 $p^{(2)}$ 满足 $p^{(1)T} A p^{(2)} = 0$ ，则 $p^{(1)}$ 、 $p^{(2)}$ 关于 $A$ 共轭。（共轭是正交概念的推广）

$\Rightarrow$ 若 $p^{(1)}$ 、 $p^{(2)}$ 称关于 $A$ 共轭，则 $p^{(1)}$ 和 $A p^{(2)}$ 正交。


■ 二次严格凸函数： $f(x) = 1/2 * (x - x^*)^T A (x - x^*)$

$\Rightarrow \nabla f(x) = A(x - x^*)$

$p^{(1)} := p_t$  ( $x^{(2)}$ 点切线方向)

$p^{(2)} := -(x^{(2)} - x^*)$

$\Rightarrow p^{(1)T} A p^{(2)} = -p_t^T \nabla f(x^{(2)}) = 0$



问题：如何保证 $p^{(1)}$ 为 $x^{(2)}$ 的切线方向？

# Fletcher-Reeves法

- 设计思想：利用梯度构造共轭方向进行迭代

迭代方向： $\mathbf{p}^{(k+1)} = -\nabla f(\mathbf{x}^{(k+1)}) + \beta_k \mathbf{p}^{(k)}$      $\mathbf{p}^{(1)} = -\nabla f(\mathbf{x}^{(1)})$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k^* \mathbf{p}^{(k)}$$

将 $\mathbf{p}^{(k+1)}$ 代入 共轭方程

$$\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k+1)} = 0$$

→  $-\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k+1)}) + \beta_k \mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)} = 0$

→ 
$$\beta_k = \frac{\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k+1)})}{\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)}}$$

**Fletcher-Reeves法**

注意：n>2时， $\mathbf{p}^{(1)}$  的共轭方向不止1个， $-\nabla f(\mathbf{x}^{(2)}) + \beta_1 \mathbf{p}^{(1)}$  未必指向 $\mathbf{x}^*$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k^* \mathbf{p}^{(k)}$$

# 二次终止性

■ 共轭方向组：若 $A$ 是 $n$ 阶正定矩阵，且 $\mathbf{p}^{(1)}, \mathbf{p}^{(2)} \dots \mathbf{p}^{(k)}$ 为 $k$ 个关于 $A$ 两两共轭的方向， $k \leq n$ ，则称这组方向关于 $A$ 共轭。

◆ 性质1：  $k \leq n$ ，则 $A$ 的 $k$ 个非零共轭方向线性无关。（反证法）

$$\text{线性相关} \quad \sum_{i=1}^k \alpha_i \mathbf{p}^{(i)} = 0 \quad \xrightarrow{1 \leq j \leq k} \sum_{i=1}^k \alpha_i \mathbf{p}^{(i)T} A \mathbf{p}^{(j)} = \alpha_j \mathbf{p}^{(j)T} A \mathbf{p}^{(j)} = 0 \quad \xrightarrow{A \text{ 正定}} \alpha_j = 0 \quad \text{矛盾}$$

◆ 性质2： 若 $f(\mathbf{x})$ 为严格凸二次函数，则  $\nabla f(\mathbf{x}^{(k+1)})^T \mathbf{p}^{(j)} = 0 \quad 1 \leq j \leq k \leq n$

$$\nabla f(\mathbf{x}^{(k+1)}) = A \mathbf{x}^{(k+1)} + \mathbf{b} = A \mathbf{x}^{(k)} + \mathbf{b} + \lambda_k^* A \mathbf{p}^{(k)} = \nabla f(\mathbf{x}^{(k)}) + \lambda_k^* A \mathbf{p}^{(k)} \quad \Rightarrow \quad \nabla f(\mathbf{x}^{(k+1)})^T \mathbf{p}^{(k-1)} = 0$$

■ 定理： 沿着 $A$ 的 $n$ 个非零共轭方向依次做一维最优步长搜索，则最多经过 $n$ 步可找到二次严格凸函数的极小值。

$$\left. \begin{array}{l} \text{性质2} \Rightarrow \nabla f(\mathbf{x}^{(k+1)})^T \mathbf{p}^{(j)} = 0 \\ 1 \leq j \leq k \leq n \end{array} \right\} \Rightarrow \nabla f(\mathbf{x}^{(n+1)})^T \left( \sum_{i=1}^n \alpha_i \mathbf{p}^{(i)} \right) = 0$$

$$\left. \begin{array}{l} \text{性质1} \Rightarrow \nabla f(\mathbf{x}^{(n+1)}) = \sum_{i=1}^n \alpha_i \mathbf{p}^{(i)} \end{array} \right\} \Rightarrow \nabla f(\mathbf{x}^{(n+1)}) = \mathbf{0}$$

# 等价公式

◆ 目的：避免求取二阶导数

共轭梯度法迭代方向： $\mathbf{p}^{(k+1)} = -\nabla f(\mathbf{x}^{(k+1)}) + \beta_k \mathbf{p}^{(k)}$

**Crowder-Wolfe**公式：

$$\beta_k = \frac{\nabla f(\mathbf{x}^{(k+1)})^T [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]}{\mathbf{p}^{(k)T} [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]}$$

**Fletcher-Reeves**公式：

$$\beta_k = \frac{\nabla f(\mathbf{x}^{(k+1)})^T \nabla f(\mathbf{x}^{(k+1)})}{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}$$

**Polak-Ribiere**公式：

$$\beta_k = \frac{\nabla f(\mathbf{x}^{(k+1)})^T [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]}{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}$$

# 自动重置

◆ 目的：保证一般 $f(x)$ 下算法的收敛性

$$\beta_k = \frac{\nabla f(\mathbf{x}^{(k+1)})^T [\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})]}{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}$$

**Polak-Ribiere公式：**

$$\beta_k \leftarrow \max \{\beta_k, 0\}$$

自动重置

$$\mathbf{p}^{(k+1)} = -\nabla f(\mathbf{x}^{(k+1)}) + \beta_k \mathbf{p}^{(k)}$$

共轭梯度法的性能介于最速下降法和牛顿法之间！



# 下降迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \quad \Rightarrow \quad f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$$

## ➤ 迭代方向

### ■ 基于梯度方法

□ 最速下降法

□ 牛顿法

□ 拟牛顿法

□ 共轭梯度法

■ 直接法

## ➤ 步长选择（一维搜索）

■ 基于梯度法

■ 直接法

## ➤ 迭代终止准则

# 最优迭代步长

- 设计思想：沿搜索方向的目标函数值最小


$$\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$$

- 基于梯度方法
- 直接法
  - **Fibonacci**斐波那契法
  - **0.618**法

# 基于梯度方法

◆ 目标:  $\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$

$$f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}) = f(\mathbf{x}^{(k)}) + \lambda \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + \frac{1}{2} \lambda^2 \mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)} + O(\lambda^2)$$

极小值   $\frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d\lambda} \approx \nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)} + \lambda \mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)} = 0$



$$\lambda^* = \frac{-\nabla f(\mathbf{x}^{(k)})^T \mathbf{p}^{(k)}}{\mathbf{p}^{(k)T} \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{p}^{(k)}}$$

- 特点:
- 1、解析解, 不需迭代
  - 2、需求Hessian矩阵
  - 3、 $\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)}$ 未必是极小值

$$h(\mathbf{x}) = g[f(\mathbf{x})]$$

$$\nabla_{\mathbf{x}} h(\mathbf{x}) = \nabla_{\mathbf{x}} f(\mathbf{x}) \nabla_f g[f(\mathbf{x})]$$

# 最速下降法的性质

■ 性质：最优步长时  $\nabla f(\mathbf{x}^{(k+1)}) \perp \nabla f(\mathbf{x}^{(k)})$

■ 证明

$$\begin{aligned} & \frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d\lambda} \\ &= \left( \frac{df(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})} \right)^T \frac{d(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})}{d\lambda} \\ &= \nabla f(\mathbf{x}^{(k+1)})^T \mathbf{p}^{(k)} \\ &= -\nabla f(\mathbf{x}^{(k+1)})^T \nabla f(\mathbf{x}^{(k)}) \\ &= 0 \end{aligned}$$

# 下降迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \quad \Rightarrow \quad f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$$

## ➤ 迭代方向

### ■ 基于梯度方法

□ 最速下降法

□ 牛顿法

□ 拟牛顿法

□ 共轭梯度法

■ 直接法

## ➤ 步长选择（一维搜索）


■ 基于梯度法

■ 直接法


## ➤ 迭代终止准则

# 分数法

- 假设:  $f(x)$ 在 $[a,b]$ 区间内单峰或无峰。假设是否合理?
- 特点: 取 $x_1, x'_1 \in (a, b)$ , 将 $[a,b]$ 分为3个区间。则最小值 $x^*$ 必定位于 $x_1$ 、 $x'_1$ 两点中目标函数值较小一点所在的两个相邻区间内。
- 算法思想: 将 $x_1$ 、 $x'_1$ 两点中目标函数值大的点作为新的边界, 不断缩小最优值所在区间的范围。




$$x^* \in [a, x'_1]$$



$$x^* \in [a, x_1]$$

# 搜索点选取

- 目标：计算量最小
- 技巧：当前目标区的搜索点可直接用于下一次搜索




问题：如果单峰点是最大值会怎样？

# 斐波那契法

## ● Fibonacci数列


$$F_n = F_{n-1} + F_{n-2}, \quad n \geq 2 \quad F_0 = 1 \quad F_1 = 1$$

n	0	1	2	3	4	5
F <sub>n</sub>	1	1	2	3	5	8





# 0.618法（黄金分割点法）



$$r*r=1-r \quad \longrightarrow \quad r^2+r-1=0 \quad \longrightarrow \quad r=0.618$$

可以证明： $\lim_{n \rightarrow \infty} \frac{F_{n-1}}{F_n} = r = 0.618$

# 下降迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)} \quad \Rightarrow \quad f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$$

- 迭代方向
  - 基于梯度方法
    - 最速下降法
    - 牛顿法
    - 拟牛顿法
    - 共轭梯度法
  - 直接法
- 步长选择（一维搜索）
  - 基于梯度法
  - 直接法
- 迭代终止准则

# 迭代终止准则

## ■ 迭代收敛准则

### ● 绝对误差准则

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \varepsilon_1$$

$$|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})| \leq \varepsilon_2$$

### ● 相对误差准则

$$\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|}{\|\mathbf{x}^{(k)}\|} \leq \varepsilon_3$$

$$\frac{|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|}{|f(\mathbf{x}^{(k)})|} \leq \varepsilon_4$$

## ■ 梯度模准则(first-order optimality measure)

$$\|\nabla f(\mathbf{x}^{(k)})\| \leq \varepsilon_5$$

$$\frac{\|\nabla f(\mathbf{x}^{(k)})\|}{\|\nabla f(\mathbf{x}^{(0)})\|} \leq \varepsilon_6$$

# 完整算法举例

- 1、设置初始点 $\mathbf{x}^{(1)}$ 、迭代终止阈值 $\varepsilon$ ,  $k=1$ ;
- 2、如果  $\|\nabla f(\mathbf{x}^{(k)})\| \leq \varepsilon$  ,  $\mathbf{x}^* = \mathbf{x}^{(k)}$  , 迭代结束。
- 3、否则继续迭代

$$\mathbf{p}^{(k)} = -\nabla f(\mathbf{x}^{(k)}) \quad \text{最速下降法}$$

$$\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{p}^{(k)})$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{p}^{(k)}$$

$k \leftarrow k+1$ , 返回第2步。

# 第六章 非线性规划

## ➤ 非线性规划数值解法

### □ 无约束极值问题


#### ● 下降迭代法

### □ 有约束极值问题

#### ● 可行方向法

#### ● 制约函数法

#### ● 逐次逼近法



# 约束极值问题的数值解法

- 可行方向法
  - **Zoutendijk**可行方向法
- 制约函数法
  - 外点法
  - 内点法
  - 混合法
- 逐次逼近法（近似规划法）
  - **SLP (Sequential Linear Programming)**
  - **SQP (Sequential Quadratic Programming)**

# Zoutendijk可行方向法

- 可行下降方向

$$\left\{ \begin{array}{l} \nabla f(\mathbf{x}^{(k)})^T \mathbf{p} < 0 \\ -\nabla g_j(\mathbf{x}^{(k)})^T \mathbf{p} < 0 \quad j \in J(\mathbf{x}^{(k)}) \end{array} \right. \xleftrightarrow{(1)} \left\{ \begin{array}{l} \nabla f(\mathbf{x}^{(k)})^T \mathbf{p} \leq \eta \\ -\nabla g_j(\mathbf{x}^{(k)})^T \mathbf{p} \leq \eta \\ \eta < 0 \end{array} \right.$$

(2)  
 $\longleftrightarrow$

$$\begin{array}{ll} \min \eta \\ s.t. & \nabla f(\mathbf{x}^{(k)})^T \mathbf{p} \leq \eta \\ & -\nabla g_j(\mathbf{x}^{(k)})^T \mathbf{p} \leq \eta \quad j \in J(\mathbf{x}^{(k)}) \\ & -1 \leq \mathbf{p} \leq 1 \end{array}$$

$\eta < 0$ : 可行下降方向

$\eta = 0$ : 迭代结束!

$\eta > 0$ : 不会出现

问题: Zoutendijk法迭代结束时找到的一定是极小点吗?

# 约束极值问题的数值解

- 可行方向法
  - **Zoutendijk**可行方向法
- 约束函数法
  - 外点法
  - 内点法
  - 混合法
- 逐次逼近法（近似规划法）
  - **SLP (Sequential Linear Programming)**
  - **SQP (Sequential Quadratic Programming)**



# 制约函数法

- 思想：化为无约束极值问题求解，
- 名称：也称为序列无约束极小化技术，  
**SUMT(Sequential Unconstrained Minimization Technique)**
- 制约函数法的种类
  - 外点法
    - 从可行域外部逼近极值
  - 内点法
    - 从可行域内部逼近极值
  - 混合法
    - 内点法和外点法的结合


# 1、外点法

■ 思想：构造罚函数，惩罚可行域外的迭代点

$$\min P(\mathbf{x}, M) = f(\mathbf{x}) + M \sum_{i=1}^m h_i^2(\mathbf{x}) + M \sum_{j=1}^l [\min(0, g_j(\mathbf{x}))]^2$$

Courant 罚函数

$M > 0$  为罚因子，当  $M$  趋向无穷时， $\mathbf{x}^*$  为原问题约束极值解。




# 解析分析举例

$$\min f(\mathbf{x}) = \frac{1}{3}(x_1 + 1)^3 + x_2$$

$$\text{s.t. } x_1 - 1 \geq 0$$

$$x_2 \geq 0$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} (x_1 + 1)^2 \\ 1 \end{bmatrix} \neq 0$$



没有内点极值

# 求解

构造罚函数：

$$P(\mathbf{x}, M) = \frac{1}{3}(x_1 + 1)^3 + x_2 + M[\min(0, x_1 - 1)]^2 + M[\min(0, x_2)]^2$$

根据一阶驻点条件，有

$$\frac{\partial P}{\partial x_1} = (x_1 + 1)^2 + 2M[\min(0, x_1 - 1)] = 0$$

$$\frac{\partial P}{\partial x_2} = 1 + 2M[\min(0, x_2)] = 0$$

如果 $x_1 \geq 1 \Rightarrow x_1 = -1$ ，矛盾

如果 $x_2 \geq 0 \Rightarrow 1 = 0$ ，不成立

所以考虑 $x_1 < 1, x_2 < 0$ 区域的驻点。（可行域外的点）

$$\frac{\partial P}{\partial x_1} = (x_1 + 1)^2 + 2M(x_1 - 1) = 0$$

$$\frac{\partial P}{\partial x_2} = 1 + 2Mx_2 = 0$$

可得：

$$\begin{cases} x_1 = -1 - M \pm \sqrt{M^2 + 4M} \\ x_2 = -\frac{1}{2M} \end{cases} \quad \begin{matrix} \mathbf{M} \rightarrow +\infty \\ \Rightarrow \end{matrix} \quad \begin{cases} x_1^* = 1 \\ x_2^* = 0 \end{cases}$$

$$\nabla^2 P(\mathbf{x}) = \begin{bmatrix} 2(x_1 + 1) + 2M & 0 \\ 0 & 2M \end{bmatrix} > 0$$

故为极小值

# 外点法的数值解法

- 构造罚函数

$$\min P(\mathbf{x}, M_k) = f(\mathbf{x}) + M_k P(\mathbf{x})$$

$$P(\mathbf{x}) \triangleq \sum_{i=1}^m h_i^2(\mathbf{x}) + \sum_{j=1}^l [\min(0, g_j(\mathbf{x}))]^2$$

1、取  $M_1 > 0$ （通常  $M_1 = 1$ ），允许误差  $\varepsilon > 0$ ， $k := 1$

2、求  $\min P(\mathbf{x}, M_k)$ ，得  $\mathbf{x}^{(k)}$ 。

3、if  $M_k P(\mathbf{x}^{(k)}) > \varepsilon$

$M_{k+1} = c M_k$  ( $c > 1$ ，通常取5或10)，

$k := k + 1$

转第2步继续迭代。

else

$\mathbf{x}^* = \mathbf{x}^{(k)}$

迭代结束

# 外点法收敛性分析

$$\nabla f(\mathbf{X}^*) - \sum_{i=1}^m \gamma_i^* \nabla h_i(\mathbf{X}^*) - \sum_{g_j(\mathbf{X}^*)=0} \mu_j^* \nabla g_j(\mathbf{X}^*) = \mathbf{0}$$

## ➤ 罚函数

$$P(\mathbf{x}, M_k) = f(\mathbf{x}) + M_k \sum_{i=1}^m h_i^2(\mathbf{x}) + M_k \sum_{j=1}^l [\min(0, g_j(\mathbf{x}))]^2$$

## ➤ 第k步罚函数的局部极小值满足

$$\nabla P(\mathbf{x}^{(k)}, M_k) = \nabla f(\mathbf{x}^{(k)}) + 2M_k \sum_{i=1}^m h_i(\mathbf{x}^{(k)}) \nabla h_i(\mathbf{x}^{(k)}) + 2M_k \sum_{g_j(\mathbf{x}^{(k)}) \leq 0} g_j(\mathbf{x}^{(k)}) \nabla g_j(\mathbf{x}^{(k)}) = \mathbf{0}$$

$$\nabla P(\mathbf{x}^{(k)}, M_k) = \nabla f(\mathbf{x}^{(k)}) - \sum_{i=1}^m \lambda_i(k) \nabla h_i(\mathbf{x}^{(k)}) - \sum_{g_j(\mathbf{x}^{(k)}) \leq 0} \mu_j(\mathbf{x}^{(k)}) \nabla g_j(\mathbf{x}^{(k)}) = \mathbf{0}$$

$$\lambda_i(k) = -2M_k h_i(\mathbf{x}^{(k)})$$

$$\mu_i^*(k) = -2M_k g_j(\mathbf{x}^{(k)}) \geq 0$$

## ➤ $\mathbf{x}^{(k)}$ 迭代收敛时

$$\nabla P(\mathbf{x}^*, M) = \nabla f(\mathbf{x}^*) - \sum_{i=1}^m \lambda_i^* \nabla h_i(\mathbf{x}^*) - \sum_{g_j(\mathbf{x}^*) \rightarrow 0} \mu_j^* \nabla g_j(\mathbf{x}^*) = \mathbf{0}$$

**KKT条件!**

如果 $\mathbf{x}^{(k)}$ 是 $\min P(\mathbf{x}, M_k)$ 的全局极小值，则外点法收敛到全局最优解！

# 外点法特点

- 1、只有 $M_k \rightarrow \infty$ ，才能保证 $\lambda^*(k) \rightarrow \lambda^*$ 、 $\mu^*(k) \rightarrow \mu^*$ ， $x^{(k)} \rightarrow x^*$ 。
- 2、 $M_k$ 过大，有可能导致Hessian矩阵病态（条件数很大），极小值将位于狭长的深谷，导致目标函数值对搜索方向敏感。

$$\text{cond}(H) = \|H\| \cdot \|H^{-1}\| \geq \lambda_{\max} / \lambda_{\min}$$

## 3、改进策略

- 1) 设计精确罚函数（例如 $l_1$ 罚函数），令有限 $M_k$ 的 $P(x, M_k)$ 驻点恰好为 $x^*$ 。
- 2) 构造增广Lagrange函数对罚函数进行修正，在有限 $M_k$ 时也能使 $x^{(k)}$ 逼近最优解 $x^*$ 。



## 2、内点法

- 算法思想：构造障碍函数，阻止迭代点离开可行域。

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r) = f(\mathbf{x}) + r \sum_{j=1}^l \frac{1}{g_j(\mathbf{x})}$$

或

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r) = f(\mathbf{x}) - r \sum_{j=1}^l \log g_j(\mathbf{x})$$

其中  $R_0 = \{\mathbf{x} \mid g_j(\mathbf{x}) > 0, j = 1, 2, \dots, l\}$  严格内点

$r > 0$  为障碍因子，其在迭代中的取值会不断减小，趋向于0，使 $\mathbf{x}$ 可趋向于边界。

# 解析分析举例

$$\min f(\mathbf{x}) = x_1 + x_2$$

$$\mathbf{s.t.} \quad -x_1^2 + x_2 \geq 0$$

$$x_1 \geq 0$$

# 求解

构造障碍函数：

$$\bar{P}(\mathbf{x}, r) = x_1 + x_2 - r \cdot [\log(-x_1^2 + x_2) + \log(x_1)]$$

根据驻点一阶条件，有

$$\frac{\partial \bar{P}}{\partial x_1} = 1 - r \cdot \frac{-2x_1}{-x_1^2 + x_2} - r \cdot \frac{1}{x_1} = 0$$

$$\frac{\partial \bar{P}}{\partial x_2} = 1 - r \cdot \frac{1}{-x_1^2 + x_2} = 0$$


求解得到：

$$x_1 = \frac{\sqrt{1+8r}-1}{4}$$

$$x_2 = \frac{3}{2}r - \frac{\sqrt{1+8r}-1}{8}$$

$r \rightarrow 0$ 时，有

$$\begin{cases} x_1^* = 0 \\ x_2^* = 0 \end{cases}$$



# 数值解法

- 构造障碍函数

$$\min_{\mathbf{x} \in R_0} \bar{P}(\mathbf{x}, r_k) = f(\mathbf{x}) - r_k \sum_{j=1}^l \log g_j(\mathbf{x})$$

1、取 $r_1 > 0$ （通常 $r_1 = 1$ ），允许误差 $\varepsilon > 0$ ， $k := 1$

2、求 $\min P(\mathbf{x}, r_k)$ ，得 $\mathbf{x}^{(k)} \in R_0$ （须保证是内点）

3、if  $\left| r_k \sum_{j=1}^l \log g_j(\mathbf{x}^{(k)}) \right| > \varepsilon$   
 $r_{k+1} = r_k / c$ ，（ $c > 1$ , 通常取5或10）  
 $k := k + 1$ 转第2步重新求解。

else

$$\mathbf{x}^* = \mathbf{x}^{(k)}$$

停止迭代。

# 内点法收敛性分析

## ➤ 障碍函数

$$\bar{P}(\mathbf{x}, r_k) = f(\mathbf{x}) - r_k \sum_{j=1}^l \log g_j(\mathbf{x})$$

## ➤ 第k步障碍函数局部极小值满足

$$\nabla \bar{P}(\mathbf{x}^{(k)}, r_k) = \nabla f(\mathbf{x}^{(k)}) - r_k \sum_{j=1}^l \frac{1}{g_j(\mathbf{x}^{(k)})} \nabla g_j(\mathbf{x}^{(k)}) = 0$$

$$\nabla \bar{P}(\mathbf{x}^{(k)}, r_k) = \nabla f(\mathbf{x}^{(k)}) - \sum_{j=1}^l \mu_j(k) \nabla g_j(\mathbf{x}^{(k)}) = 0 \quad \mu_j(k) = \frac{r_k}{g_j(\mathbf{x}^{(k)})} \geq 0$$

## ➤ $\mathbf{x}_k^*$ 迭代收敛时

$$\nabla \bar{P}(\mathbf{x}^*, r) = \nabla f(\mathbf{x}^*) - \sum_{j=1}^l \mu_j^* \nabla g_j(\mathbf{x}^*) = 0$$

$$\mu_j^* = \frac{r}{g_j(\mathbf{x}^*)} \geq 0$$

$$\mu_j^* g_j(\mathbf{x}^*) = r \rightarrow 0$$

**KKT条件!**

如果 $\mathbf{x}^{(k)}$ 是 $\min P(\mathbf{x}, r_k)$ 的全局极小值，则内点法收敛到全局最优解！

# 混合法

- 内点法不能处理等式约束问题
- 外点法不能处理目标函数在可行域外不存在的问题
- 对等式约束和当前不被满足的不等式约束，使用罚函数法，对满足的不等式约束，使用障碍函数法。

# 约束极值问题的数值解

- 可行方向法
  - **Zoutendijk可行方向法**
- 约束函数法
  - 外点法
  - 内点法
  - 混合法
- 逐次逼近法（近似规划法）
  - **SLP (Sequential Linear Programming)**
  - **SQP (Sequential Quadratic Programming)**



# 逐次逼近法

- 思想: **Taylor**展开近似为简单规划问题
- 序贯线性规划法**SLP (Sequential Linear Programming)**
- 序贯二次规划法**SQP (Sequential Quadratic Programming)**

# 一般约束极值问题

$$\min f(\mathbf{x})$$

$$\text{s.t.} \quad h_i(\mathbf{x}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}) \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x} \in R^n$$

求解思路：通过低阶近似，化为容易求解的规划问题

# 序贯线性规划法SLP

$$\min f(\mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)})$$

$$\text{s.t.} \quad h_i(\mathbf{x}^{(k)}) + \nabla h_i(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}^{(k)}) + \nabla g_j(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) \geq 0 \quad j = 1, 2, \dots, l$$

$$|x_s - x_s^{(k)}| \leq \delta_s^{(k)} \quad s = 1, 2, \dots, n \quad \delta_s^{(k)} \text{是步长限制量}$$

设第 $k$ 步线性规划的最优解为 $\mathbf{x}^{*(k)}$

当 $\mathbf{x}^{*(k)}$ 是可行解时，取  $\delta_s^{(k+1)} = \delta_s^{(k)}$  ,  $\mathbf{x}^{(k+1)} = \mathbf{x}^{*(k)}$  继续迭代;

当 $\mathbf{x}^{*(k)}$ 不是可行解时，取  $\delta_s^{(k)} = \beta \delta_s^{(k)}$  ,  $\beta < 1$  , 重新寻优;

当  $|\delta_s^{(k)}| < \varepsilon, \forall s = 1, 2, \dots, n$  或  $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon$  时，迭代结束。

# 序贯二次规划法SQP

起作用约束集法序贯求解如下近似问题

$$\min f(\Delta \mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \nabla^2 f(\mathbf{x}^{(k)}) \Delta \mathbf{x}$$

$$\text{s.t.} \quad h_i(\mathbf{x}^{(k)}) + \nabla h_i(\mathbf{x}^{(k)})^T \Delta \mathbf{x} = 0 \quad i = 1, 2, \dots, m$$

$$g_j(\mathbf{x}^{(k)}) + \nabla g_j(\mathbf{x}^{(k)})^T \Delta \mathbf{x} \geq 0 \quad j = 1, 2, \dots, l$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta \mathbf{x}^*$$